CP352101
Data Science Textbook
อ.ธนพล ตั้งชูพงศ์
Dark Mode

หน้าหลัก
1 Data Science คืออะไร?
2 การตั้งคำถามและกำหนดปัญหา
3 Python สำหรับ Data Science
4 การเก็บข้อมูลและ Pandas
5 การทำความสะอาดและแปลงข้อมูล
6 สถิติเชิงพรรณนา EDA และ Data Visual
7 แนะนำ Machine Learning
8 Regression — การทำนายค่าต่อเนื่อง
9 Classification — การจำแนกประเภท
10 Ensemble Methods
11 Clustering — การจัดกลุ่มข้อมูล
  Unsupervised Learning
  K-Means Algorithm
  การเลือก K
  Cluster Profiling
  การทดสอบทางสถิติสำหรับ Clusters
  Storytelling และ Domain Expert Collabora
  สรุปท้ายบทที่ 11
  เอกสารอ้างอิงประจำบทที่ 11
  แบบฝึกหัดท้ายบทที่ 11
12 Model Validation และ Selection
13 Data Storytelling และการเขียนรายงาน
14 โครงงาน Data Science: End-to-End Pr
อภิธานศัพท์
ดรรชนี

บทที่ 11: Clustering — การจัดกลุ่มข้อมูล

ภาค 3: Machine Learning CLO: CLO3, CLO5 **สัปดาห์:** 12

วัตถุประสงค์การเรียนรู้

เมื่อศึกษาบทนี้จบแล้ว นักศึกษาจะสามารถ:

1. อธิบายแนวคิด Unsupervised Learning และความแตกต่างจาก Supervised ได้
2. อธิบายขั้นตอน K-Means Algorithm ได้
3. เลือกจำนวน K ที่เหมาะสมด้วย Elbow Method และ Silhouette Score ได้
4. วิเคราะห์และตีความ Cluster Profiling ได้
5. ใช้การทดสอบทางสถิติ (ANOVA, Kruskal-Wallis) เปรียบเทียบ Cluster ได้
6. นำเสนอผล Clustering ร่วมกับ Domain Expert ได้

Unsupervised Learning

ในกระบวนการวิเคราะห์ข้อมูลและการพัฒนาระบบปัญญาประดิษฐ์ (Artificial Intelligence) การเรียนรู้ของเครื่อง (Machine Learning) ถือเป็นเครื่องมือหลักที่นักวิทยาศาสตร์ข้อมูล (Data Scientist) นำมาประยุกต์ใช้เพื่อสกัดองค์ความรู้จากข้อมูล อย่างไรก็ตาม ข้อมูลที่เกิดขึ้นในโลกแห่งความเป็นจริง (Real-world data) มักเป็นข้อมูลที่ไม่ได้ถูกจัดระเบียบหรือไม่มีการระบุผลลัพธ์ล่วงหน้า (Unlabeled data) การจัดการกับข้อมูลลักษณะนี้จึงต้องอาศัยกระบวนทัศน์ที่เรียกว่า **Unsupervised Learning** หรือการเรียนรู้แบบไม่มีผู้สอน

Unsupervised Learning คือแขนงหนึ่งของ Machine Learning ที่โมเดลทางคณิตศาสตร์จะพยายามค้นหาโครงสร้างที่ซ่อนอยู่ (Hidden structure) รูปแบบ (Patterns) หรือความสัมพันธ์ภายในชุดข้อมูล โดยปราศจากการชี้นำจากตัวแปรเป้าหมาย (Target variable) หรือผลเฉลย (Ground truth) (James et al., 2023) แตกต่างจากการเรียนรู้แบบมีผู้สอน (Supervised Learning) ที่โมเดลเรียนรู้จากชุดข้อมูลที่มีการระบุคำตอบที่ถูกต้องไว้แล้ว

พิจารณาในเชิงคณิตศาสตร์ หากกำหนดให้เมทริกซ์ X มิติ $n \times p$ เป็นตัวแทนของชุดข้อมูล โดย n คือจำนวนข้อมูล (Observations) และ p คือจำนวนคุณลักษณะ (Features) ใน Unsupervised Learning เราจะมีเพียงข้อมูล X เท่านั้น เป้าหมายคือการเรียนรู้คุณสมบัติบางประการของ X โดยไม่มีเวกเตอร์ของผลลัพธ์ y มาคอยปรับแก้ความผิดพลาดของโมเดล

Supervised vs Unsupervised Learning

เพื่อทำความเข้าใจลักษณะเฉพาะของ Unsupervised Learning อย่างถ่องแท้ จำเป็นต้องเปรียบเทียบกับ Supervised Learning ซึ่งเป็นแนวทางที่นักศึกษาได้ทำความคุ้นเคยมาแล้วในบทก่อนหน้า ความแตกต่างที่สำคัญสามารถสรุปได้ดังตารางที่ 11.1

ตารางที่ 11.1 การเปรียบเทียบระหว่าง Supervised Learning และ Unsupervised Learning

คุณลักษณะ	Supervised Learning (การเรียนรู้แบบมีผู้สอน)	Unsupervised Learning (การเรียนรู้แบบไม่มีผู้สอน)
ข้อมูลนำเข้า (Input Data)	ข้อมูลที่มีป้ายกำกับ (Labeled data: X และ y)	ข้อมูลที่ไม่มีป้ายกำกับ (Unlabeled data: X เท่านั้น)
เป้าหมายหลัก (Goal)	ทำนายผลลัพธ์ (Prediction) สำหรับข้อมูลใหม่	ค้นหาโครงสร้าง รูปแบบ หรือจัดกลุ่มข้อมูล (Exploration)
การประเมินผล (Evaluation)	ประเมินได้ชัดเจนผ่านตัวชี้วัด เช่น Accuracy, RMSE, F1-Score	ประเมินได้ยาก มักมีความเป็นอัตวิสัย (Subjectivity) สูง
ความซับซ้อนในการเตรียมข้อมูล	สูงมาก เนื่องจากต้องใช้ทรัพยากรมนุษย์ในการทำ Label ข้อมูล	ต่ำกว่า สามารถนำข้อมูลดิบมาผ่านกระบวนการทำความสะอาดแล้วใช้ได้ทันที
ประเภทของงาน (Task Types)	Classification, Regression	Clustering, Dimensionality Reduction, Association Rules

ตัวอย่างเปรียบเทียบในบริบทการใช้งานจริง: สมมติว่าธนาคารพาณิชย์แห่งหนึ่งต้องการวิเคราะห์ข้อมูลบัตรเครดิต * **Supervised Learning:** ธนาคารมีข้อมูลประวัติลูกค้าที่เคย “ผิดนัดชำระหนี้” (Default = 1) และ “ชำระปกติ” (Default = 0) ธนาคารสร้างโมเดลเพื่อ **ทำนาย** ว่าลูกค้ารายใหม่มีแนวโน้มจะผิดนัดชำระหนี้หรือไม่ * **Unsupervised Learning:** ธนาคารมีเพียงข้อมูลพฤติกรรมการรูดซื้อสินค้า (เช่น ยอดใช้จ่ายหมวดร้านอาหาร หมวดท่องเที่ยว หมวดช้อปปิ้งออนไลน์) ธนาคารสร้างโมเดลเพื่อ **จัดกลุ่ม** ลูกค้าที่มีพฤติกรรมคล้ายคลึงกันเข้าด้วยกัน เพื่อนำไปออกแบบโปรโมชันที่เหมาะสม โดยที่ธนาคารไม่ทราบล่วงหน้าว่าลูกค้าจะถูกแบ่งออกเป็นกี่กลุ่มและมีลักษณะอย่างไร

Use Cases: กรณีศึกษาและการประยุกต์ใช้งานจริง

Unsupervised Learning ถูกนำมาใช้อย่างแพร่หลายในภาคธุรกิจและอุตสาหกรรม โดยเฉพาะเมื่อเผชิญกับชุดข้อมูลขนาดใหญ่ (Big Data) ที่การให้มนุษย์มานั่งระบุป้ายกำกับ (Labeling) เป็นเรื่องที่เป็นไปไม่ได้ในทางปฏิบัติ กรณีศึกษาที่สำคัญมีดังต่อไปนี้

Customer Segmentation (การแบ่งกลุ่มลูกค้า)

Customer Segmentation คือกระบวนการแบ่งฐานลูกค้าออกเป็นกลุ่มย่อย (Clusters) โดยอ้างอิงจากคุณลักษณะที่คล้ายคลึงกัน เช่น ข้อมูลประชากรศาสตร์ (Demographics) หรือพฤติกรรมการใช้งาน (Behavioral data) * **ตัวอย่างในแพลตฟอร์ม E-Commerce ของไทย:** แอปพลิเคชันอย่าง Shopee หรือ Lazada นำข้อมูลการคลิกดูสินค้า ระยะเวลาที่อยู่ในแอปพลิเคชัน และประวัติการซื้อ มาประมวลผลด้วยอัลกอริทึม Clustering โมเดลอาจค้นพบกลุ่มลูกค้าที่ “ชอบล่าโค้ดส่งฟรีช่วงเที่ยงคืน” หรือกลุ่ม “ซื้อสินค้าอิเล็กทรอนิกส์ราคาสูงแต่ไม่สนใจโปรโมชัน” จากนั้นทีมการตลาด (Marketing) จะนำข้อมูลเชิงลึก (Insights) นี้ไปทำ Personalized Campaign ซึ่งมีประสิทธิภาพกว่าการหว่านโฆษณาแบบเดียวกันให้ทุกคนแบบ Mass Marketing

Anomaly Detection (การตรวจจับความผิดปกติ)

Anomaly Detection หรือ Outlier Detection คือการค้นหาข้อมูลที่มีลักษณะเบี่ยงเบนไปจากพฤติกรรมส่วนใหญ่ของชุดข้อมูลอย่างมีนัยสำคัญ ข้อมูลเหล่านี้มักบ่งชี้ถึงเหตุการณ์ที่ผิดปกติ ข้อผิดพลาด หรือการทุจริต * **ตัวอย่างในระบบสาธารณสุขไทย:** สำนักงานหลักประกันสุขภาพแห่งชาติ (สปสช.) จัดการกับข้อมูลการเบิกจ่ายค่ารักษาพยาบาลจากคลินิกและโรงพยาบาลทั่วประเทศนับล้านรายการต่อเดือน การใช้ Unsupervised Learning สามารถช่วยตรวจจับอคติหรือความผิดปกติในการเบิกจ่าย (Fraud Detection) เช่น คลินิกแห่งหนึ่งมีการเบิกจ่ายค่ายาประเภทหนึ่งในปริมาณที่สูงผิดปกติเมื่อเทียบกับคลินิกอื่นในภูมิภาคเดียวกันที่มีขนาดเท่ากัน โมเดลจะทำการตั้งค่าสถานะ (Flag) ข้อมูลนี้เพื่อให้เจ้าหน้าที่ตรวจสอบเชิงลึกต่อไป โดยไม่จำเป็นต้องมีข้อมูลประวัติการทุจริตในอดีตมาสอนโมเดลล่วงหน้า

Topic Modeling (การจัดกลุ่มหัวข้อ)

ในสาขาการประมวลผลภาษาธรรมชาติ (Natural Language Processing: NLP) Topic Modeling เป็นเทคนิค Unsupervised Learning ที่ใช้สำหรับสกัดหัวข้อหลัก (Topics) ที่ซ่อนอยู่ในคลังเอกสารขนาดใหญ่ (Corpus) * **ตัวอย่างในระดับมหาวิทยาลัย:** ศูนย์บริหารระบบข้อมูลของมหาวิทยาลัยขอนแก่น ได้รับข้อความประเมินการสอนแบบปลายเปิด (Free-text feedback) จากนักศึกษาหลายหมื่นคนในแต่ละภาคการศึกษา การอ่านทีละข้อความเพื่อสรุปประเด็นเป็นเรื่องที่ใช้เวลามาก การประยุกต์ใช้อัลกอริทึมอย่าง Latent Dirichlet Allocation (LDA) สามารถจัดกลุ่มคำที่มักปรากฏร่วมกัน และสรุปออกมาเป็นหัวข้อได้ เช่น โมเดลอาจพบหัวข้อที่ประกอบด้วยคำว่า {“แอร์”, “ห้องเรียน”, “ร้อน”, “ซ่อม”} หรือ {“เอกสาร”, “สไลด์”, “อ่านยาก”, “อัปโหลด”} ทำให้ผู้บริหารสามารถมองเห็นภาพรวมของปัญหาและปรับปรุงคุณภาพการศึกษาได้อย่างตรงจุด

โค้ดตัวอย่าง: การทำงานของ Unsupervised Learning เบื้องต้น

เพื่อให้เห็นภาพการทำงานของ Unsupervised Learning อย่างเป็นรูปธรรม พิจารณาตัวอย่างโค้ด Python ด้านล่าง ซึ่งจำลองการสร้างชุดข้อมูลที่ไม่มีป้ายกำกับ (Unlabeled data) และใช้อัลกอริทึม K-Means (ซึ่งจะกล่าวถึงรายละเอียดใน Section ถัดไป) ในการค้นหาโครงสร้างและจัดกลุ่มข้อมูล (VanderPlas, 2016)

```python
# นำเข้าไลบรารีที่จำเป็น
import matplotlib.pyplot as plt
from sklearn.datasets import make_blobs
from sklearn.cluster import KMeans

# 1. สร้างชุดข้อมูลจำลอง (Synthetic Data)
# สร้างข้อมูล 2 มิติ จำนวน 300 จุด โดยให้มีศูนย์กลางกลุ่มข้อมูล 4 จุด
# สังเกตว่าเราเก็บค่า feature ไว้ในตัวแปร X เท่านั้น (ละทิ้งตัวแปร y ที่เป็นป้ายกำกับ)
X, _ = make_blobs(n_samples=300, centers=4, cluster_std=0.60, random_state=42)

# 2. จำลองสถานการณ์: นำข้อมูลไปพล็อตกราฟก่อนการวิเคราะห์
# ในมุมมองของ Unsupervised Learning เราจะเห็นเพียงจุดข้อมูลที่กระจัดกระจายโดยไม่มีสีแบ่งแยก
plt.figure(figsize=(12, 5))

plt.subplot(1, 2, 1)
plt.scatter(X[:, 0], X[:, 1], s=50, color='gray', alpha=0.7)
plt.title("ข้อมูลดิบ (Unlabeled Data)")
plt.xlabel("Feature 1")
plt.ylabel("Feature 2")

# 3. สร้างและฝึกสอนโมเดล Unsupervised Learning (K-Means Clustering)
# กำหนดให้โมเดลพยายามมองหาโครงสร้างข้อมูลและแบ่งเป็น 4 กลุ่ม
kmeans = KMeans(n_clusters=4, random_state=42, n_init=10)
kmeans.fit(X) # สังเกตว่าใช้คำสั่ง fit(X) โดยไม่มี y

# 4. ให้โมเดลทำนาย (จัดกลุ่ม) ข้อมูลแต่ละจุด
predicted_clusters = kmeans.predict(X)

# 5. พล็อตกราฟแสดงผลลัพธ์ที่โมเดลค้นพบ
plt.subplot(1, 2, 2)
# ระบายสีตามกลุ่มที่โมเดลค้นพบ (predicted_clusters)
plt.scatter(X[:, 0], X[:, 1], c=predicted_clusters, s=50, cmap='viridis', alpha=0.7)

# พล็อตจุดศูนย์กลางของแต่ละกลุ่ม (Centroids) ที่โมเดลคำนวณได้
centers = kmeans.cluster_centers_
plt.scatter(centers[:, 0], centers[:, 1], c='red', s=200, marker='X', label='Centroids')

plt.title("ผลลัพธ์จากการทำ Clustering")
plt.xlabel("Feature 1")
plt.legend()

plt.tight_layout()
plt.show()
```

ผลลัพธ์จากการรัน:

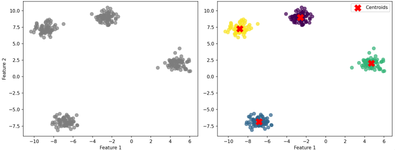

Unsupervised Learning: Clustering Result

จากโค้ดตัวอย่าง จะเห็นได้ว่าอัลกอริทึมสามารถแบ่งกลุ่มข้อมูลออกจากกันได้โดยอาศัยเพียงระยะห่างทางคณิตศาสตร์ระหว่างจุดข้อมูล (Features) โดยที่ผู้เขียนโปรแกรมไม่ได้ระบุล่วงหน้าว่าจุดใดควรอยู่กลุ่มใด นี่คือแก่นแท้ของการทำงานแบบ Unsupervised Learning

ข้อดีและข้อจำกัดของ Unsupervised Learning

การเลือกใช้ Unsupervised Learning ในโครงงานวิทยาการข้อมูล จำเป็นต้องตระหนักถึงทั้งศักยภาพและข้อจำกัดของกระบวนทัศน์นี้

ข้อดี (Advantages): 1. **ลดต้นทุนในการเตรียมข้อมูล:** การสร้างชุดข้อมูลแบบมีป้ายกำกับ (Labeled dataset) ต้องใช้แรงงานมนุษย์ เวลา และงบประมาณมหาศาล (เช่น การจ้างแพทย์มานั่งระบุฟิล์มเอ็กซเรย์หลายหมื่นใบ) Unsupervised Learning ช่วยขจัดข้อจำกัดนี้ ทำให้สามารถใช้ประโยชน์จากข้อมูลดิบจำนวนมหาศาล (Unlabeled Big Data) ได้ทันที 2. **ค้นพบองค์ความรู้ใหม่ (Serendipity in Data):** เนื่องจากโมเดลไม่ได้ถูกตีกรอบด้วยผลลัพธ์ที่มนุษย์กำหนดไว้ล่วงหน้า โมเดลจึงมีอิสระในการค้นพบรูปแบบหรือความสัมพันธ์ที่ซับซ้อน ซึ่งมนุษย์อาจคาดไม่ถึงหรือมองข้ามไป 3. **ใช้เป็นกระบวนการเตรียมข้อมูล (Preprocessing):** เทคนิค Unsupervised Learning หลายประเภท (เช่น Principal Component Analysis: PCA) ถูกนำมาใช้เพื่อลดรูปมิติข้อมูล (Dimensionality Reduction) หรือสกัดคุณลักษณะใหม่ (Feature Extraction) ก่อนที่จะส่งข้อมูลนั้นไปประมวลผลต่อด้วยโมเดล Supervised Learning ซึ่งจะช่วยเพิ่มประสิทธิภาพและลดระยะเวลาในการประมวลผลได้

ข้อจำกัด (Limitations): 1. **ความยากในการประเมินผล (Difficulty in Evaluation):** เนื่องจากไม่มีผลเฉลย (Ground Truth) การวัดว่าโมเดลทำงานได้ “ดี” เพียงใดจึงเป็นเรื่องยาก ไม่มีตัวชี้วัดที่ตายตัวและชัดเจนเหมือนค่าความแม่นยำ (Accuracy) ใน Supervised Learning การประเมินมักต้องอาศัยการวัดความหนาแน่นของกลุ่มข้อมูลเชิงคณิตศาสตร์ หรือต้องพึ่งพาวิจารณญาณของผู้เชี่ยวชาญเฉพาะทาง (Domain Expert) 2. **ผลลัพธ์มีความเป็นอัตวิสัย (Subjectivity):** เมื่ออัลกอริทึมจัดกลุ่มข้อมูลเสร็จสิ้น โมเดลจะบอกได้เพียงว่าข้อมูลจุดนี้อยู่ “กลุ่มที่ 1” หรือ “กลุ่มที่ 2” แต่มันไม่สามารถอธิบายได้ว่ากลุ่มที่ 1 คืออะไร การตีความหมายของแต่ละกลุ่ม (Interpretation) จึงตกเป็นภาระของนักวิทยาศาสตร์ข้อมูล ซึ่งอาจเกิดความลำเอียง (Bias) ในการตีความได้ 3. **ความซับซ้อนในการคำนวณ (Computational Complexity):** อัลกอริทึม Unsupervised Learning หลายตัว (เช่น Hierarchical Clustering) ต้องคำนวณระยะห่างระหว่างจุดข้อมูลทุกคู่ ซึ่งจะใช้ทรัพยากรหน่วยประมวลผล (CPU/Memory) สูงมากเมื่อขนาดของข้อมูล (n) เพิ่มขึ้น ส่งผลให้ไม่สามารถสเกล (Scale) ระบบเพื่อรองรับข้อมูลขนาดใหญ่มากๆ ได้โดยง่าย

สรุปประเด็นสำคัญ (Key Takeaways)

- **Unsupervised Learning** คือการเรียนรู้ของเครื่องที่พยายามค้นหาโครงสร้าง รูปแบบ หรือการจัดกลุ่มชุดข้อมูล โดยใช้เฉพาะข้อมูลนำเข้า (Features, X) ปราศจากป้ายกำกับหรือตัวแปรเป้าหมาย (Target, y)
- การใช้งานที่โดดเด่น ได้แก่ **Customer Segmentation** (การแบ่งกลุ่มลูกค้าตามพฤติกรรม), **Anomaly Detection** (การตรวจจับข้อมูลที่ผิดปกติหรือการทุจริต) และ **Topic Modeling** (การสกัดหัวข้อจากคลังข้อความขนาดใหญ่)
- ข้อดีที่สำคัญคือสามารถใช้งานกับข้อมูลดิบที่ไม่มีป้ายกำกับซึ่งมีอยู่มหาศาลได้อย่างรวดเร็ว และช่วยค้นพบความรู้ใหม่ที่มนุษย์อาจคาดไม่ถึง
- ความท้าทายหลักคือ **การประเมินประสิทธิภาพที่ทำได้ยาก** และ **ความจำเป็นในการใช้ผู้เชี่ยวชาญ (Domain Expert)** เพื่อตีความหมายของผลลัพธ์ที่โมเดลค้นพบ

คำถามท้าย Section

1. หากมหาวิทยาลัยขอนแก่นต้องการพัฒนาระบบ AI เพื่อคัดกรองนักศึกษาที่มีภาวะเสี่ยงเป็นโรคซึมเศร้าจากข้อมูลพฤติกรรมการเข้าใช้งานระบบ e-Learning และการยืมหนังสือในห้องสมุด โดยที่มหาวิทยาลัย *ไม่เคยมี* การเก็บสถิติมาก่อนว่าพฤติกรรมแบบใดคือผู้ป่วยโรคซึมเศร้า นักศึกษาจะเลือกใช้ Supervised หรือ Unsupervised Learning ในช่วงเริ่มต้นโครงการ? พร้อมอธิบายเหตุผล
2. “ใน Unsupervised Learning โมเดลที่แบ่งกลุ่มข้อมูลออกเป็น 10 กลุ่ม ย่อมมีประสิทธิภาพดีกว่าโมเดลที่แบ่งข้อมูลออกเป็น 3 กลุ่มเสมอ” นักศึกษาเห็นด้วยกับคำกล่าวนี้หรือไม่? เพราะเหตุใดจงอธิบายโดยอ้างอิงถึงข้อจำกัดของการประเมินผลใน Unsupervised Learning

K-Means Algorithm

K-Means เป็นหนึ่งในอัลกอริทึมการจัดกลุ่มข้อมูล (Clustering) แบบ Unsupervised Learning ที่ได้รับความนิยมสูงสุด เนื่องจากมีความเรียบง่าย มีประสิทธิภาพในการประมวลผลสูง และสามารถนำไปประยุกต์ใช้กับข้อมูลขนาดใหญ่ได้ดี หลักการพื้นฐานของ K-Means คือการแบ่งชุดข้อมูลออกเป็นกลุ่มย่อยจำนวน K กลุ่ม โดยที่ข้อมูลในกลุ่มเดียวกันจะมีลักษณะคล้ายคลึงกันมากที่สุด และข้อมูลที่อยู่ต่างกลุ่มกันจะมีลักษณะแตกต่างกันมากที่สุด (James et al., 2023)

อัลกอริทึมนี้ใช้ **จุดศูนย์กลางของกลุ่ม (Centroid)** เป็นตัวแทนของแต่ละกลุ่ม และใช้มาตรวัดระยะทาง (Distance Metric) เช่น Euclidean Distance ในการประเมินความคล้ายคลึงระหว่างจุดข้อมูลกับจุดศูนย์กลาง เป้าหมายทางคณิตศาสตร์ของ K-Means คือการลดค่าผลรวมความแปรปรวนภายในกลุ่ม (Within-Cluster Sum of Squares: WCSS หรือ Inertia) ให้เหลือน้อยที่สุด

สมการของ WCSS สามารถเขียนได้ดังนี้:

$$WCSS = \sum_{k=1}^{K} \sum_{x_i \in C_k} ||x_i - \mu_k||^2$$

โดยที่: * K คือ จำนวนกลุ่มที่ต้องการแบ่ง * C_k คือ กลุ่มข้อมูลที่ k * x_i คือ จุดข้อมูลที่อยู่ในกลุ่ม C_k * μ_k คือ จุดศูนย์กลาง (Centroid) ของกลุ่ม C_k * $||x_i - \mu_k||^2$ คือ ระยะทาง Euclidean ยกกำลังสอง ระหว่างจุดข้อมูล x_i กับจุดศูนย์กลาง μ_k

ขั้นตอนการทำงานของอัลกอริทึม (Step-by-step Algorithm)

K-Means ทำงานแบบวนซ้ำ (Iterative Process) โดยมีขั้นตอนการทำงานหลัก 4 ขั้นตอน ดังแผนภาพด้านล่าง:

```
+---------------------------------------------------+

|               เริ่มต้น (Start)                   |
+---------------------------------------------------+
                         |
                         v
+---------------------------------------------------+

| 1. Initialization: กำหนดค่า K และสุ่มจุด Centroids  |
+---------------------------------------------------+
                         |
                         v
+---------------------------------------------------+

| 2. Assignment: จัดข้อมูลเข้ากลุ่มที่ Centroid ใกล้สุด |<---+
+---------------------------------------------------+    |

                         |                               |
                         v                               |
+---------------------------------------------------+    |

| 3. Update: คำนวณหาจุด Centroid ใหม่ของแต่ละกลุ่ม      |    |
+---------------------------------------------------+    |

                         |                               |
                         v                               |
+---------------------------------------------------+    |

| 4. Convergence Check: Centroids เปลี่ยนแปลงหรือไม่? |----+ (ถ้ามีการเปลี่ยนแปลง)
+---------------------------------------------------+
                         | (ถ้าไม่มีการเปลี่ยนแปลง / ลู่เข้าสู่คำตอบ)
                         v
+---------------------------------------------------+

|                  สิ้นสุด (End)                     |
+---------------------------------------------------+
```

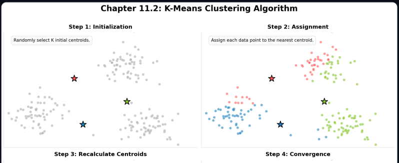

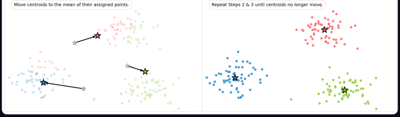

K-Means Algorithm Steps

คำอธิบายรายละเอียดแต่ละขั้นตอน:

1. **Initialization (การกำหนดจุดเริ่มต้น):** กำหนดจำนวนกลุ่ม *K* ที่ต้องการ จากนั้นอัลกอริทึมจะสุ่มเลือกจุดข้อมูลจำนวน *K* จุดในพื้นที่ของข้อมูล (Feature Space) เพื่อทำหน้าที่เป็นจุดศูนย์กลางเริ่มต้น (Initial Centroids)
2. **Assignment (การกำหนดกลุ่มให้ข้อมูล):** คำนวณระยะทางจากจุดข้อมูลทุกจุดไปยัง Centroids ทั้ง *K* จุด จากนั้นกำหนดให้จุดข้อมูลเป็นสมาชิกของกลุ่มที่มี Centroid อยู่ใกล้ที่สุด
3. **Update (การปรับปรุงจุดศูนย์กลาง):** เมื่อข้อมูลทุกจุดถูกจัดกลุ่มแล้ว อัลกอริทึมจะคำนวณหาตำแหน่งของ Centroid ใหม่ โดยหาค่าเฉลี่ย (Mean) ของพิกัดข้อมูลทุกจุดที่อยู่ในกลุ่มนั้น
4. **Convergence (การตรวจสอบการลู่เข้า):** ทำขั้นตอนที่ 2 และ 3 ซ้ำไปเรื่อยๆ จนกว่าจะเข้าเงื่อนไขการลู่เข้า (Convergence) ซึ่งจะกล่าวถึงในหัวข้อ 11.2.4

ความสำคัญของการปรับมาตราส่วนข้อมูล (Feature Scaling)

เนื่องจาก K-Means ใช้ระยะทาง (Distance) ในการจัดกลุ่มข้อมูล ดังนั้น **การปรับมาตราส่วนข้อมูล (Feature Scaling) จึงเป็นขั้นตอนที่ขาดไม่ได้เด็ดขาด** หากตัวแปร (Features) มีหน่วยหรือสเกลที่แตกต่างกันมาก ตัวแปรที่มีค่าตัวเลขสูงกว่าจะมีอิทธิพลต่อการคำนวณระยะทางมากกว่าตัวแปรที่มีค่าตัวเลขต่ำ ซึ่งจะทำให้โมเดลเกิดความเอนเอียง (Bias)

ตัวอย่างบริบทประเทศไทย: พิจารณาการจัดกลุ่มลูกค้าของแพลตฟอร์ม E-commerce แห่งหนึ่ง โดยใช้ตัวแปร 2 ตัว ได้แก่: 1. `Age`: อายุของลูกค้า (18 ถึง 60 ปี) 2. `Total_Spent`: ยอดใช้จ่ายสะสม (5,000 ถึง 500,000 บาท)

หากคำนวณ Euclidean distance ระหว่างลูกค้าสองคนโดยไม่ทำ Scaling ความแตกต่างของยอดใช้จ่ายสะสม (หลักแสน) จะกลบความแตกต่างของอายุ (หลักสิบ) ไปจนหมด ทำให้ K-Means จัดกลุ่มโดยพิจารณาจากยอดใช้จ่ายเพียงอย่างเดียว

ลูกค้า	อายุ (ปี)	ยอดใช้จ่าย (บาท)
A	20	10,000
B	22	10,500
C	55	10,000

หากไม่ทำ Scaling ระยะทางระหว่าง A กับ C (ต่างวัย ยอดซื้อเท่ากัน) จะใกล้กันมากกว่า A กับ B (วัยเดียวกัน ยอดซื้อต่างกันเล็กน้อย) ซึ่งอาจขัดแย้งกับพฤติกรรมผู้บริโภคที่แท้จริง

วิธีการทำ Feature Scaling ที่นิยมใช้ร่วมกับ K-Means คือ **Standardization (Z-score normalization)** ซึ่งเป็นการปรับข้อมูลให้มีค่าเฉลี่ยเท่ากับ 0 และส่วนเบี่ยงเบนมาตรฐานเท่ากับ 1 (VanderPlas, 2016)

การกำหนดจุดศูนย์กลางเริ่มต้นและพารามิเตอร์ n_init

ข้อจำกัดสำคัญประการหนึ่งของ K-Means แบบดั้งเดิมคือ ปัญหา **Random Initialization Trap** หากในขั้นตอนแรกมีการสุ่มจุด Centroids ที่ไม่ดี (เช่น ไปกระจุกตัวอยู่บริเวณเดียวกัน) อัลกอริทึมอาจลู่เข้าสู่จุดต่ำสุดสัมพัทธ์ (Local Optima) แทนที่จะเป็นจุดต่ำสุดสัมบูรณ์ (Global Optima) ส่งผลให้ผลลัพธ์การจัดกลุ่มไม่มีประสิทธิภาพ

เพื่อแก้ไขปัญหานี้ ไลบรารีอย่าง `scikit-learn` จึงมีแนวทางจัดการ 2 วิธี:

1. **การใช้อัลกอริทึม K-Means++:** เป็นวิธีการสุ่มจุดเริ่มต้นอย่างชาญฉลาด โดยจะสุ่มจุดแรกขึ้นมาก่อน จากนั้นจุดถัดๆ ไปจะถูกสุ่มโดยให้มีโอกาสตกอยู่ในบริเวณที่อยู่ห่างจาก Centroid ที่มีอยู่เดิมมากที่สุด วิธีนี้ช่วยลดโอกาสการเกิด Local Optima ได้อย่างมีนัยสำคัญ
2. **พารามิเตอร์ `n_init`:** เป็นการสั่งให้อัลกอริทึมรันกระบวนการ K-Means ทั้งหมดซ้ำหลายๆ รอบ โดยใช้จุดเริ่มต้นที่สุ่มขึ้นมาใหม่ในแต่ละรอบ (ค่าเริ่มต้นของ `n_init` มักตั้งไว้ที่ 10) จากนั้นโมเดลจะเลือกผลลัพธ์จากการรันรอบที่ให้ค่า WCSS ต่ำที่สุดมาเป็นผลลัพธ์สุดท้าย

การลู่เข้าสู่คำตอบ (Convergence)

อัลกอริทึม K-Means จะหยุดทำงานเมื่อเข้าสู่สภาวะ Convergence ซึ่งในทางปฏิบัติจะเกิดขึ้นเมื่อเข้าเงื่อนไขใดเงื่อนไขหนึ่งต่อไปนี้:

1. **Centroid ไม่มีการเปลี่ยนแปลง:** ตำแหน่งของจุดศูนย์กลางในรอบปัจจุบัน ไม่ต่างจากรอบที่แล้ว (หรือเปลี่ยนแปลงน้อยกว่าค่าความคลาดเคลื่อนที่ยอมรับได้ ซึ่งกำหนดด้วยพารามิเตอร์ `tol` ใน `scikit-learn`)
2. **การกำหนดกลุ่มข้อมูลคงที่:** ไม่มีจุดข้อมูลใดถูกย้ายข้ามกลุ่มในการวนซ้ำรอบล่าสุด
3. **ถึงจำนวนรอบสูงสุดที่กำหนด (Max Iterations):** เพื่อป้องกันไม่ให้อัลกอริทึมทำงานไม่รู้จบในกรณีที่ข้อมูลมีความซับซ้อนมาก จะมีการกำหนดพารามิเตอร์ `max_iter` (ค่าเริ่มต้นมักเป็น 300) หากวนซ้ำครบจำนวนแล้วแม้อาจจะยังไม่ลู่เข้าอย่างสมบูรณ์ อัลกอริทึมก็จะหยุดทำงาน

การประยุกต์ใช้ K-Means ด้วย Python

ตัวอย่างต่อไปนี้จำลองการทำงานกับข้อมูลนักศึกษามหาวิทยาลัยขอนแก่น (ข้อมูลสมมติ) จำนวน 300 คน โดยต้องการจัดกลุ่มนักศึกษาตามพฤติกรรมการใช้ห้องสมุดและเกรดเฉลี่ยสะสม (GPAX) เพื่อให้สำนักหอสมุดสามารถจัดแคมเปญส่งเสริมการอ่านได้ตรงกลุ่มเป้าหมาย

```python
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.cluster import KMeans
from sklearn.preprocessing import StandardScaler
from sklearn.datasets import make_blobs

# 1. สร้างชุดข้อมูลจำลอง (นักศึกษา 300 คน, 3 กลุ่มพฤติกรรม)
X, y_true = make_blobs(n_samples=300, centers=3, cluster_std=0.8, random_state=42)
# แปลงตัวเลขให้สมจริง: Feature 0 เป็น GPAX (สเกล 0-4), Feature 1 เป็น จำนวนครั้งที่เข้าห้องสมุดต่อเทอม (สเกล 0-50)
X[:, 0] = np.interp(X[:, 0], (X[:, 0].min(), X[:, 0].max()), (1.5, 4.0))
X[:, 1] = np.interp(X[:, 1], (X[:, 1].min(), X[:, 1].max()), (0, 50))

df_students = pd.DataFrame(X, columns=['GPAX', 'Library_Visits'])

# 2. การทำ Feature Scaling (สำคัญมาก)
scaler = StandardScaler()
X_scaled = scaler.fit_transform(df_students)

# 3. สร้างและฝึกสอนโมเดล K-Means
# กำหนด K=3, ใช้ K-Means++, รัน 10 รอบ (n_init), วนซ้ำสูงสุด 300 รอบ (max_iter)
kmeans = KMeans(n_clusters=3, init='k-means++', n_init=10, max_iter=300, random_state=42)
kmeans.fit(X_scaled)
```

```python
# นำผลลัพธ์การจัดกลุ่มกลับไปใส่ใน DataFrame
df_students['Cluster'] = kmeans.labels_

# 4. ดึงค่าพิกัดจุดศูนย์กลาง (Centroids) และแปลงกลับเป็นสเกลเดิมเพื่อให้ตีความหมายได้
centroids_scaled = kmeans.cluster_centers_
centroids_original = scaler.inverse_transform(centroids_scaled)

# 5. การแสดงผลด้วยกราฟ (Visualization)
plt.figure(figsize=(8, 6))

# พล็อตจุดข้อมูลแต่ละกลุ่ม
colors = ['#1f77b4', '#ff7f0e', '#2ca02c']
for i in range(3):
    cluster_data = df_students[df_students['Cluster'] == i]
    plt.scatter(cluster_data['GPAX'], cluster_data['Library_Visits'],
                c=colors[i], label=f'Cluster {i}', alpha=0.6, edgecolors='w', s=60)

# พล็อตจุด Centroids
plt.scatter(centroids_original[:, 0], centroids_original[:, 1],
            c='red', marker='X', s=200, label='Centroids', edgecolors='black')

plt.title('Student Segmentation based on GPAX and Library Visits (KKU)', fontsize=14)
plt.xlabel('GPAX', fontsize=12)
plt.ylabel('Library Visits (per semester)', fontsize=12)
plt.legend()
plt.grid(True, linestyle='--', alpha=0.5)
plt.show()

# พิมพ์ผลสรุปของแต่ละกลุ่ม
print("สรุปคุณลักษณะของแต่ละกลุ่ม (Centroids):")
for i, centroid in enumerate(centroids_original):
    print(f"Cluster {i}: GPAX เฉลี่ย = {centroid[0]:.2f}, จำนวนเข้าห้องสมุดเฉลี่ย = {centroid[1]:.0f} ครั้ง")
```

ผลลัพธ์จากการรัน:

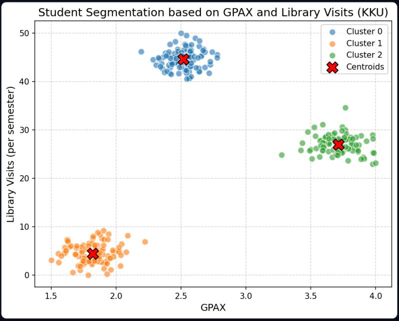

Student Segmentation

```
สรุปคุณลักษณะของแต่ละกลุ่ม (Centroids):
Cluster 0: GPAX เฉลี่ย = 2.52, จำนวนเข้าห้องสมุดเฉลี่ย = 45 ครั้ง
Cluster 1: GPAX เฉลี่ย = 1.82, จำนวนเข้าห้องสมุดเฉลี่ย = 4 ครั้ง
Cluster 2: GPAX เฉลี่ย = 3.71, จำนวนเข้าห้องสมุดเฉลี่ย = 27 ครั้ง
```

จากโค้ดตัวอย่างข้างต้น จะเห็นได้ว่าขั้นตอนที่ 2 (Feature Scaling) มีความสำคัญอย่างยิ่ง หากข้ามขั้นตอนนี้ โมเดลจะให้ความสำคัญกับ `Library_Visits` (สเกล 0-50) มากกว่า `GPAX` (สเกล 1.5-4.0) อย่างมหาศาล และจุดศูนย์กลาง (Centroids) สีแดงในกราฟ จะแสดงให้เห็นถึงตัวแทนที่ดีที่สุดของนักศึกษาในแต่ละกลุ่มย่อย

สรุปประเด็นสำคัญ

- **อัลกอริทึมลู่เข้า (Iterative Convergence):** K-Means ทำงานแบบวนซ้ำระหว่างการจัดกลุ่มข้อมูล (Assignment) และการอัปเดตจุดศูนย์กลาง (Update) จนกว่าจุดศูนย์กลางจะไม่เปลี่ยนแปลง
- **การปรับมาตราส่วน (Feature Scaling):** เป็นสิ่งที่บังคับต้องทำก่อนใช้ K-Means เสมอ เนื่องจากอัลกอริทึมใช้ระยะทาง (Euclidean Distance) ในการคำนวณ หากไม่ปรับสเกล ตัวแปรที่มีค่าตัวเลขสูงจะครอบงำโมเดล
- **การหลีกเลี่ยง Local Optima:** ปัญหาการสุ่มจุดเริ่มต้นที่ไม่ดี แก้ไขได้ด้วยการใช้อัลกอริทึม K-Means++ ควบคู่กับการกำหนดพารามิเตอร์ `n_init` เพื่อรันอัลกอริทึมหลายรอบและเลือกผลลัพธ์ที่ดีที่สุด
- **เกณฑ์การหยุดทำงาน:** โมเดลจะหยุดทำงานเมื่อเข้าสู่สภาวะ Convergence (ไม่มีการเปลี่ยนแปลง) หรือเมื่อวนซ้ำจนครบกำหนด `max_iter`

คำถามท้าย Section

1. หากนักศึกษาต้องการนำ K-Means ไปใช้จัดกลุ่มผู้ป่วยโรคเบาหวานของโรงพยาบาลศรีนครินทร์ โดยมีตัวแปรคือ “อายุ (ปี)” และ “ระดับน้ำตาลในเลือด (mg/dL)” นักศึกษาคิดว่าหากไม่ทำ Feature Scaling จะเกิดผลกระทบต่อการจัดกลุ่มอย่างไร จงอธิบาย
2. พารามิเตอร์ `n_init` ในไลบรารี `scikit-learn` มีหน้าที่อะไร และเหตุใดจึงมีความจำเป็นต่อความเสถียร (Stability) ของผลลัพธ์ที่ได้จากการทำ K-Means
3. จงอธิบายความแตกต่างระหว่างสถานะ Convergence ทางทฤษฎี กับการหยุดทำงานเนื่องจากพารามิเตอร์ `max_iter`

การเลือก K

ความท้าทายที่สำคัญที่สุดประการหนึ่งในการทำ Clustering ด้วยอัลกอริทึมอย่าง K-Means คือการกำหนดค่าพารามิเตอร์ *K* (จำนวนกลุ่ม) ไว้ล่วงหน้า เนื่องจาก Clustering เป็นการเรียนรู้แบบไม่มีผู้สอน (Unsupervised Learning) ข้อมูลจึงไม่มีป้ายกำกับ (Ground Truth) ที่จะนำมาใช้คำนวณค่าความแม่นยำ (Accuracy) หรือข้อผิดพลาด (Error) ได้โดยตรงเหมือนใน Supervised Learning (James et al., 2023)

การเลือกค่า K ที่น้อยเกินไปอาจทำให้ข้อมูลที่มีลักษณะแตกต่างกันถูกบังคับให้อยู่ในกลุ่มเดียวกัน (Underfitting) ในขณะที่การเลือกค่า K ที่มากเกินไปอาจทำให้กลุ่มที่ได้ไม่มีความหมายในเชิงปฏิบัติการ หรือโมเดลทำการจับกลุ่มสัญญาณรบกวน (Overfitting) ใน Section นี้ จะพิจารณาวิธีการทางสถิติและวิธีการเชิงประยุกต์เพื่อค้นหาค่า K ที่เหมาะสมที่สุด

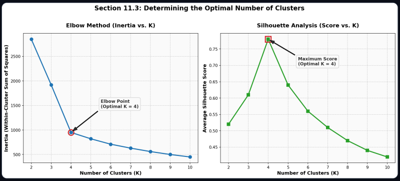

Elbow Method & Silhouette Score

Inertia และ Elbow Method

Inertia หรือ Within-Cluster Sum of Squares (WCSS) คือมาตรวัดที่คำนวณผลรวมของระยะทางกำลังสองระหว่างจุดข้อมูลแต่ละจุดกับจุดศูนย์กลางกลุ่ม (Centroid) ที่จุดข้อมูลนั้นสังกัดอยู่ ค่า Inertia สามารถเขียนเป็นสมการทางคณิตศาสตร์ได้ดังนี้:

$$\text{Inertia} = \sum_{k=1}^{K} \sum_{x_i \in C_k} ||x_i - \mu_k||^2$$

โดยที่: - K คือ จำนวนกลุ่มทั้งหมด - C_k คือ กลุ่มที่ k - x_i คือ จุดข้อมูลที่อยู่ในกลุ่ม C_k - μ_k คือ จุดศูนย์กลาง (Centroid) ของกลุ่ม C_k

เป้าหมายของ K-Means คือการทำให้ค่า Inertia มีค่าน้อยที่สุด อย่างไรก็ตาม หากเราเพิ่มค่า K ไปเรื่อย ๆ ค่า Inertia จะลดลงเสมอ (หาก K เท่ากับจำนวนจุดข้อมูล ค่า Inertia จะเป็น 0) ดังนั้น การใช้ค่า Inertia เพียงอย่างเดียวจึงไม่สามารถบอกค่า K ที่ดีที่สุดได้

Elbow Method (วิธีข้อศอก) เป็นเทคนิคเชิงกราฟิกที่ช่วยแก้ปัญหานี้ โดยมีหลักการคือ ให้รันอัลกอริทึม K-Means ด้วยค่า K ที่แตกต่างกัน (เช่น ตั้งแต่ 1 ถึง 10) จากนั้นนำค่า Inertia ของแต่ละ K มาพิจารณาสร้างกราฟเส้น (Line Plot)

เมื่อสังเกตกราฟ จะพบว่าในช่วงแรก (ค่า K น้อย) ค่า Inertia จะลดลงอย่างรวดเร็ว แต่เมื่อถึงจุดหนึ่ง อัตราการลดลงของ Inertia จะเริ่มชะลอตัวและกราฟจะเริ่มแบนราบ จุดที่กราฟมีการหักมุมอย่างชัดเจนคล้าย “ข้อศอก” (Elbow) คือค่า K ที่เหมาะสมที่สุด เนื่องจากเป็นจุดที่การเพิ่มจำนวนกลุ่มไม่ได้ช่วยลดความคลาดเคลื่อนอย่างมีนัยสำคัญอีกต่อไป

ตัวอย่างในบริบทประเทศไทย: พิจารณาแพลตฟอร์ม E-commerce ของไทยที่ต้องการแบ่งกลุ่มลูกค้า (Customer Segmentation) จากข้อมูล “ยอดสั่งซื้อรวมต่อปี” และ “จำนวนครั้งที่เข้าชมเว็บไซต์” เพื่อจัดแคมเปญส่งเสริมการขาย

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.cluster import KMeans
from sklearn.datasets import make_blobs

# จำลองข้อมูลลูกค้า E-commerce จำนวน 500 ราย (แบ่งเป็น 4 กลุ่มโดยธรรมชาติ)
# Feature 1: ยอดสั่งซื้อรวมต่อปี (สเกลแล้ว), Feature 2: จำนวนครั้งที่เข้าชมเว็บไซต์ (สเกลแล้ว)
X, _ = make_blobs(n_samples=500, centers=4, cluster_std=0.8, random_state=42)

# คำนวณค่า Inertia สำหรับ K ตั้งแต่ 1 ถึง 10
inertia_values = []
K_range = range(1, 11)

for k in K_range:
    kmeans = KMeans(n_clusters=k, init='k-means++', random_state=42, n_init=10)
    kmeans.fit(X)
    inertia_values.append(kmeans.inertia_) # เก็บค่า Inertia ของแต่ละ K

# สร้างกราฟ Elbow Method
plt.figure(figsize=(8, 5))
plt.plot(K_range, inertia_values, marker='o', linestyle='-', color='b')
plt.title('Elbow Method สำหรับการจัดกลุ่มลูกค้า E-commerce')
plt.xlabel('จำนวนกลุ่ม (K)')
plt.ylabel('Inertia (WCSS)')
plt.xticks(K_range)
plt.grid(True, linestyle='--', alpha=0.7)
plt.show()
```

ผลลัพธ์จากการรัน:

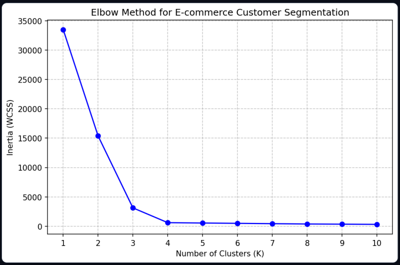

Elbow Method

จากโค้ดข้างต้น เมื่อรันโปรแกรม กราฟจะแสดงการหักมุมอย่างชัดเจนที่ K = 4 ซึ่งบ่งชี้ว่าการแบ่งลูกค้าเป็น 4 กลุ่มเป็นทางเลือกที่มีประสิทธิภาพในเชิงโครงสร้างข้อมูล

ข้อจำกัดของ Elbow Method: ในข้อมูลจริงที่ไม่มีโครงสร้างกลุ่มที่ชัดเจน (Overlapping clusters) กราฟอาจจะมีความโค้งมนอย่างต่อเนื่องโดยไม่มีจุด “ข้อศอก” ที่สังเกตได้ชัดเจน ทำให้การตัดสินใจเลือก K ด้วยวิธีนี้มีความคลุมเครือและขึ้นอยู่กับดุลยพินิจของผู้วิเคราะห์ (VanderPlas, 2016)

Silhouette Score และ Silhouette Plot

เนื่องจากข้อจำกัดของ Elbow Method การใช้ **Silhouette Score** จึงเป็นอีกหนึ่งทางเลือกที่ให้ผลลัพธ์ทางสถิติที่ชัดเจนกว่า Silhouette Score เป็นมาตรวัดที่ประเมินพฤติกรรม 2 ด้านของ Clustering ได้แก่: 1. **Cohesion (ความเกาะกลุ่ม):** จุดข้อมูลมีความใกล้ชิดกับจุดอื่น ๆ ในกลุ่มเดียวกันมากเพียงใด 2. **Separation (ความแยกห่าง):** จุดข้อมูลมีความห่างไกลจากกลุ่มอื่น ๆ มากเพียงใด

สำหรับจุดข้อมูล i ใด ๆ ค่า Silhouette Coefficient ($s(i)$) คำนวณได้จาก:

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

โดยที่: - $a(i)$ คือ ระยะทางเฉลี่ยจากจุด i ไปยังทุกจุด **ในกลุ่มเดียวกัน** (ยิ่งน้อยยิ่งดี) - $b(i)$ คือ ระยะทางเฉลี่ยจากจุด i ไปยังทุกจุด **ในกลุ่มที่ใกล้ที่สุดถัดไป** (ยิ่งมากยิ่งดี)

ค่า Silhouette Score ของโมเดลคือค่าเฉลี่ยของ $s(i)$ จากทุกจุดข้อมูลใน Dataset โดยค่าที่ได้จะมีช่วงตั้งแต่ -1 ถึง 1: - **ค่าเข้าใกล้ 1:** ข้อมูลถูกจัดกลุ่มได้ดีมาก จุดข้อมูลอยู่ใกล้สมาชิกในกลุ่มตนเองและห่างจากกลุ่มอื่น - **ค่าเข้าใกล้ 0:** จุดข้อมูลอยู่บริเวณรอยต่อ (Boundary) ระหว่าง 2 กลุ่ม - **ค่าเข้าใกล้ -1:** จุดข้อมูลน่าจะถูกจัดอยู่ในกลุ่มที่ผิด

Silhouette Plot นอกจากการดูค่าเฉลี่ยแล้ว การสร้าง Silhouette Plot จะช่วยให้เห็นการกระจายตัวของค่า $s(i)$ ในแต่ละกลุ่ม โดยความหนาของกราฟแสดงถึงจำนวนข้อมูลในกลุ่มนั้น และความยาวแสดงถึงค่า Silhouette Score กลุ่มที่ดีควรมีกราฟที่ยื่นผ่านเส้นค่าเฉลี่ยรวม และมีความหนาใกล้เคียงกัน

ตัวอย่างในบริบทประเทศไทย: พิจารณาโรงพยาบาลมหาวิทยาลัยที่ต้องการจัดกลุ่มผู้ป่วยโรคเบาหวานตาม “ระดับน้ำตาลในเลือดสะสม (HbA1c)” และ “ดัชนีมวลกาย (BMI)” เพื่อวางแผนการรักษา

```python
from sklearn.metrics import silhouette_score
import matplotlib.cm as cm

# ใช้ข้อมูล X จากตัวอย่างก่อนหน้า (จำลองเป็นข้อมูลผู้ป่วย)
silhouette_scores = []
K_range_sil = range(2, 7) # Silhouette Score ต้องมีอย่างน้อย 2 กลุ่ม

for k in K_range_sil:
    kmeans = KMeans(n_clusters=k, random_state=42, n_init=10)
    cluster_labels = kmeans.fit_predict(X)

    # คำนวณค่าเฉลี่ย Silhouette Score
    silhouette_avg = silhouette_score(X, cluster_labels)
    silhouette_scores.append(silhouette_avg)
    print(f"สำหรับ K = {k}, ค่าเฉลี่ย Silhouette Score คือ: {silhouette_avg:.4f}")

# สร้างกราฟเปรียบเทียบ Silhouette Score
plt.figure(figsize=(8, 5))
plt.bar(K_range_sil, silhouette_scores, color='teal', alpha=0.7)
plt.title('Silhouette Score สำหรับการจัดกลุ่มผู้ป่วย (ยิ่งสูงยิ่งดี)')
plt.xlabel('จำนวนกลุ่ม (K)')
plt.ylabel('Average Silhouette Score')
plt.ylim(0, 1)
plt.grid(axis='y', linestyle='--', alpha=0.7)
plt.show()
```

ผลลัพธ์จากการรัน:

```
สำหรับ K = 2, ค่าเฉลี่ย Silhouette Score คือ: 0.6072
สำหรับ K = 3, ค่าเฉลี่ย Silhouette Score คือ: 0.7819
สำหรับ K = 4, ค่าเฉลี่ย Silhouette Score คือ: 0.8336
สำหรับ K = 5, ค่าเฉลี่ย Silhouette Score คือ: 0.7005
สำหรับ K = 6, ค่าเฉลี่ย Silhouette Score คือ: 0.5635
```

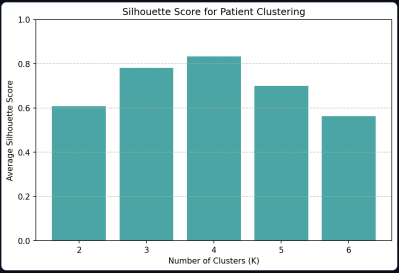

Silhouette Score
จากการพิจารณาค่า Silhouette Score ค่า K ที่ให้คะแนนสูงสุดจะเป็นค่าที่เหมาะสมที่สุดในเชิงสถิติ

ข้อจำกัดของ Silhouette Score: การคำนวณระยะทางระหว่างทุกจุดข้อมูล (Pairwise distances) ทำให้มีความซับซ้อนเชิงเวลา (Time Complexity) สูงถึง $O(N^2)$ ซึ่งไม่เหมาะกับ Dataset ที่มีขนาดใหญ่มาก (Big Data) นอกจากนี้ มาตรวัดนี้ยังมีอคติต่อรูปร่างกลุ่มที่เป็นทรงกลม (Spherical clusters) หากข้อมูลมีรูปร่างซับซ้อน (เช่น วงแหวนซ้อนกัน) Silhouette Score อาจประเมินผลผิดพลาด (McKinney, 2022)

การใช้ความรู้เฉพาะทาง (Domain Knowledge)

ในหลายสถานการณ์ทางธุรกิจ โครงสร้างทางคณิตศาสตร์ของข้อมูล (ที่หาได้จาก Elbow หรือ Silhouette) อาจไม่สอดคล้องกับข้อจำกัดหรือเป้าหมายในการนำไปใช้งานจริง (Actionability) การใช้ **Domain Knowledge** หรือความรู้เฉพาะทางในสายอาชีพนั้น ๆ จึงเป็นปัจจัยชี้ขาดในการเลือกค่า K

อัลกอริทึมไม่สามารถรับรู้ถึงงบประมาณ ข้อบังคับทางกฎหมาย หรือข้อจำกัดด้านทรัพยากรบุคคลขององค์กรได้ ดังนั้น นักวิทยาศาสตร์ข้อมูล (Data Scientist) ต้องทำงานร่วมกับผู้เชี่ยวชาญเฉพาะด้าน (Domain Experts) เพื่อกำหนด K ที่มีประโยชน์ที่สุด

ตัวอย่างในบริบทประเทศไทย:

1. **ระบบธนาคารพาณิชย์:** สมมติว่าธนาคารแห่งหนึ่งทำการรัน K-Means เพื่อแบ่งกลุ่มลูกค้าบัตรเครดิต ค่า Silhouette Score แนะนำให้เลือก K = 6 อย่างไรก็ตาม ฝ่ายการตลาดมีงบประมาณและทีมงานเพียงพอสำหรับการออกแบบแคมเปญส่งเสริมการขายเพียง 3 รูปแบบเท่านั้น (เช่น บัตรเงิน, บัตรทอง, บัตรแพลตตินัม) ในกรณีนี้ การเลือก **K = 3** ตาม Domain Knowledge ย่อมมีประสิทธิภาพในการนำไป

ปฏิบัติจริงมากกว่าการเลือก K = 6 ตามสถิติ

2. **การจัดการศึกษาระดับมหาวิทยาลัย:** คณะวิทยาการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น ต้องการจัดกลุ่มนักศึกษาชั้นปีที่ 1 ตามผลการเรียนวิชาพื้นฐาน (Programming และ Math) เพื่อจัดโครงการติวเสริม (Mentorship Program) กราฟ Elbow Method อาจไม่แสดงจุดหักมุมที่ชัดเจน แต่ภาควิชามีรุ่นพี่ผู้ช่วยสอน (TA) ที่เชี่ยวชาญในลักษณะปัญหาที่แตกต่างกันอยู่ 4 ทีม ดังนั้น อาจารย์ผู้สอนจึงกำหนดให้ **K = 4** เพื่อให้นักศึกษาแต่ละกลุ่มถูกจับคู่กับทีม TA ได้พอดี

ข้อจำกัดของการใช้ Domain Knowledge: การพึ่งพาความรู้เฉพาะทางมากเกินไปอาจนำไปสู่การเกิดอคติ (Human Bias) ผู้วิเคราะห์อาจบังคับให้ข้อมูลเข้ากับกรอบความคิดเดิมที่มีอยู่ (Preconceived notions) ทำให้พลาดโอกาสในการค้นพบรูปแบบใหม่ ๆ (Hidden patterns) ที่ซ่อนอยู่ในข้อมูล ซึ่งเป็นจุดประสงค์หลักของการทำ Unsupervised Learning (Knaflic, 2015)

เปรียบเทียบข้อจำกัดของแต่ละวิธี

เพื่อประกอบการตัดสินใจ ตารางด้านล่างสรุปภาพรวมและข้อจำกัดของทั้ง 3 วิธีในการเลือก K

วิธีการประเมิน	ข้อดี (Pros)	ข้อจำกัด (Cons / Limitations)	สถานการณ์ที่เหมาะสม
Elbow Method	เข้าใจง่าย, คำนวณรวดเร็ว (ใช้ค่า Inertia ที่ K-Means ต้องคำนวณอยู่แล้ว)	มักไม่มีจุด “ข้อศอก” ที่ชัดเจนในข้อมูลจริง ทำให้การตีความมีความเป็นอัตวิสัย (Subjective)	ข้อมูลที่มีการแยกกลุ่มกันอย่างชัดเจน และต้องการความรวดเร็ว
Silhouette Score	ให้ตัวเลขที่ชัดเจนสำหรับการเปรียบเทียบ, ประเมินทั้งความเกาะกลุ่มและความแยกห่าง	ใช้เวลาประมวลผลนาน ($O(N^2)$), มีอคติต่อกลุ่มข้อมูลที่เป็นทรงกลม (Convex shapes)	ชุดข้อมูลขนาดเล็กถึงขนาดกลาง ที่ต้องการความแม่นยำสูง
Domain Knowledge	ผลลัพธ์สามารถนำไปใช้งานได้จริง (Actionable), สอดคล้องกับข้อจำกัดทางธุรกิจ	อาจเกิดอคติจากมนุษย์, อาจขัดแย้งกับโครงสร้างทางสถิติที่แท้จริงของข้อมูล	มีข้อจำกัดทางธุรกิจที่ชัดเจน เช่น จำนวนแพ็กเกจสินค้า งบประมาณ

ในทางปฏิบัติ นักวิทยาศาสตร์ข้อมูลที่ดีจะไม่พึ่งพาวิธีใดวิธีหนึ่งเพียงอย่างเดียว แต่จะใช้ Elbow Method และ Silhouette Score เพื่อหาช่วงของค่า K ที่เป็นไปได้ทางสถิติ (เช่น K ควรอยู่ระหว่าง 3 ถึง 5) จากนั้นจึงนำผลลัพธ์ไปหารือกับผู้เชี่ยวชาญทางธุรกิจ (Domain Knowledge) เพื่อเลือกค่า K สุดท้ายที่สร้างมูลค่าได้สูงสุด

สรุปประเด็นสำคัญ

- การเลือกค่า K ใน K-Means เป็นสิ่งจำเป็น เนื่องจากเป็น Unsupervised Learning ที่ไม่มีคำตอบที่ถูกต้องตายตัว
- **Elbow Method** พิจารณาจากค่า Inertia โดยมองหาจุดที่อัตราการลดลงของความคลาดเคลื่อนเริ่มชะลอตัว (จุดข้อศอก)
- **Silhouette Score** ประเมินคุณภาพของกลุ่มจากความเกาะกลุ่ม (Cohesion) และความแยกห่าง (Separation) โดยมีค่าตั้งแต่ -1 ถึง 1 (ยิ่งเข้าใกล้ 1 ยิ่งดี)
- **Domain Knowledge** คือการเลือก K ตามบริบททางธุรกิจและข้อจำกัดในโลกความเป็นจริง ซึ่งมักเป็นปัจจัยตัดสินใจขั้นสุดท้าย
- ไม่มีวิธีใดที่สมบูรณ์แบบ การวิเคราะห์ข้อมูลที่มีประสิทธิภาพควรใช้วิธีทางสถิติควบคู่ไปกับความรู้เฉพาะทาง

คำถามชวนคิดท้าย Section

1. หากท่านใช้ Elbow Method แล้วพบว่ากราฟเป็นเส้นโค้งลงอย่างเรียบเนียนโดยไม่มีจุด “ข้อศอก” ที่ชัดเจน ท่านจะใช้กระบวนการใดต่อไปเพื่อตัดสินใจเลือกค่า K?
2. สมมติว่าท่านเป็น Data Scientist ในโรงพยาบาล ค่า Silhouette Score บ่งชี้ว่าผู้ป่วยควรแบ่งเป็น 5 กลุ่ม แต่ผู้อำนวยการโรงพยาบาลระบุว่ามีบุคลากรทางการแพทย์รองรับโปรแกรมการรักษาได้เพียง 3 รูปแบบ ท่านจะอธิบายและหาทางออกสำหรับความขัดแย้งระหว่างข้อมูลและข้อจำกัดทางธุรกิจนี้อย่างไร?

Cluster Profiling

กระบวนการทำ Clustering ด้วยอัลกอริทึมเช่น K-Means หรือ Hierarchical Clustering จะให้ผลลัพธ์เชิงตัวเลขออกมาในรูปแบบของป้ายกำกับกลุ่ม (Cluster Labels) เช่น กลุ่มที่ 0, กลุ่มที่ 1 และ กลุ่มที่ 2 อย่างไรก็ตาม ตัวเลขเหล่านี้ไม่มีความหมายในตัวมันเองในเชิงธุรกิจหรือเชิงบริบทของข้อมูล (Domain Context) การวิเคราะห์เพื่อทำความเข้าใจลักษณะเฉพาะ (Characteristics) ของแต่ละกลุ่มข้อมูล เรียกว่า **Cluster Profiling** ซึ่งเป็นขั้นตอนที่สำคัญที่สุดในการเชื่อมโยงผลลัพธ์ทางคณิตศาสตร์เข้ากับการนำไปใช้ประโยชน์จริง (Actionable Insights) (Knaflic, 2015)

การทำ Cluster Profiling ประกอบด้วยเทคนิคหลัก 4 ส่วน ได้แก่ การวิเคราะห์จุดศูนย์กลาง (Centroid Analysis), การสร้างแผนภาพความร้อนแสดงความเบี่ยงเบน (Deviation Heatmap), การวิเคราะห์ปัจจัยหลักที่กำหนดกลุ่ม (Cluster Drivers) และการตั้งชื่อกลุ่ม (Naming Clusters)

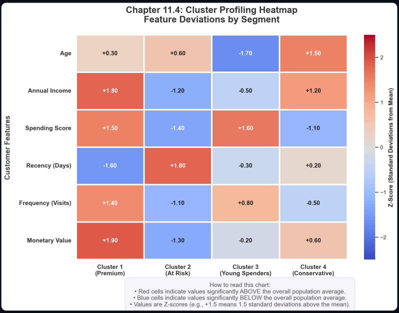

How to read this chart:
• Red cells indicate values significantly ABOVE the overall population average.
• Blue cells indicate values significantly BELOW the overall population average.
• Values are Z-scores (e.g., +1.5 means 1.5 standard deviations above the mean).

Cluster Profiling

Centroid Analysis (การวิเคราะห์จุดศูนย์กลางของกลุ่ม)

Centroid Analysis คือการคำนวณและเปรียบเทียบค่าสถิติเชิงพรรณนา (Descriptive Statistics) โดยเฉพาะค่าเฉลี่ย (Mean) หรือค่ามัธยฐาน (Median) ของตัวแปร (Features) ต่างๆ ภายในแต่ละกลุ่ม (Cluster) เทียบกับค่าเฉลี่ยรวมของข้อมูลทั้งหมด (Global Mean) (McKinney, 2022)

การวิเคราะห์นี้ช่วยให้ผู้วิเคราะห์สามารถตอบคำถามได้ว่า “สมาชิกในกลุ่มนี้มีค่าเฉลี่ยของตัวแปรแต่ละตัวเป็นเท่าใด และแตกต่างจากค่าเฉลี่ยของประชากรทั้งหมดอย่างไร”

ตัวอย่างในบริบทประเทศไทย: พิจารณาแพลตฟอร์ม E-commerce ที่ต้องการจัดกลุ่มพฤติกรรมลูกค้าโดยใช้โมเดล RFM (Recency: จำนวนวันที่ซื้อล่าสุด, Frequency: ความถี่ในการซื้อ, Monetary: ยอดใช้จ่ายรวม)

ตัวแปร	กลุ่มที่ 0 (Cluster 0)	กลุ่มที่ 1 (Cluster 1)	กลุ่มที่ 2 (Cluster 2)	ค่าเฉลี่ยรวม (Global Mean)
Recency (วัน)	15.2	120.5	5.1	46.9
Frequency (ครั้ง/ปี)	5.4	1.2	25.8	10.8
Monetary (บาท/ปี)	4,500	800	45,000	16,766

จากตาราง จะสังเกตเห็นลักษณะเฉพาะของแต่ละกลุ่มได้อย่างชัดเจน เช่น กลุ่มที่ 2 มียอดใช้จ่าย (Monetary) และความถี่ (Frequency) สูงกว่าค่าเฉลี่ยรวมอย่างมาก ในขณะที่กลุ่มที่ 1 มีจำนวนวันที่ซื้อล่าสุด (Recency) สูงมาก แสดงถึงการห่างหายจากการซื้อสินค้า

```
import pandas as pd
import numpy as np

# 1. สร้างข้อมูลจำลองของลูกค้า E-commerce จำนวน 1000 ราย
np.random.seed(42)
data = {
    'Recency': np.random.randint(1, 180, 1000),
    'Frequency': np.random.randint(1, 30, 1000),
    'Monetary': np.random.randint(500, 50000, 1000),
    # สมมติว่าอัลกอริทึม K-Means ได้กำหนด Cluster Label มาให้แล้ว
    'Cluster_Label': np.random.choice([0, 1, 2], 1000)
}
df = pd.DataFrame(data)

# 2. คำนวณค่าเฉลี่ยของแต่ละ Cluster (Centroid)
cluster_means = df.groupby('Cluster_Label').mean()

# 3. คำนวณค่าเฉลี่ยรวมทั้งหมด (Global Mean)
global_mean = df.drop('Cluster_Label', axis=1).mean()
global_mean.name = 'Global_Mean'

# 4. รวมข้อมูลเพื่อเปรียบเทียบ
centroid_analysis = cluster_means.append(global_mean)
print("ผลการวิเคราะห์ Centroid Analysis:")
print(centroid_analysis.round(2))
```

ผลลัพธ์จากการรัน:

```
ผลการวิเคราะห์ Centroid Analysis:
             Recency  Frequency  Monetary
0              85.97      15.26  26280.53
1              92.46      14.89  27136.32
2              93.09      15.34  25400.56
Global_Mean    90.45      15.17  26256.95
```

Deviation Heatmap (แผนภาพความร้อนแสดงความเบี่ยงเบน)

แม้ว่าตาราง Centroid Analysis จะให้ข้อมูลที่แม่นยำ แต่เมื่อจำนวนตัวแปร (Features) และจำนวนกลุ่ม (Clusters) มีมาก การอ่านตัวเลขดิบจะทำได้ยากและใช้เวลา การสร้างแผนภาพความร้อนแสดงความเบี่ยงเบน (Deviation Heatmap) จึงเป็นเครื่องมือที่ช่วยให้มองเห็นความแตกต่างได้อย่างรวดเร็ว (VanderPlas, 2016)

หลักการของ Deviation Heatmap คือการแปลงค่าเฉลี่ยของกลุ่มให้อยู่ในรูปของ **ร้อยละความเบี่ยงเบนจากค่าเฉลี่ยรวม (Percentage Deviation from Global Mean)** โดยใช้สมการ:

$$Deviation(\%) = \left(\frac{ClusterMean - GlobalMean}{GlobalMean} \right) \times 100$$

ตัวอย่างในบริบทมหาวิทยาลัย: พิจารณาข้อมูลพฤติกรรมของนักศึกษามหาวิทยาลัยขอนแก่น ประกอบด้วย เกรดเฉลี่ย (GPA), ชั่วโมงการเข้าใช้ห้องสมุด (Library_Hours), และชั่วโมงการทำกิจกรรมเสริมหลักสูตร (Activity_Hours)

```
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt

# 1. สร้างข้อมูลจำลองพฤติกรรมนักศึกษา
np.random.seed(101)
student_data = pd.DataFrame({
    'GPA': np.random.uniform(2.0, 4.0, 300),
    'Library_Hours': np.random.randint(0, 40, 300),
    'Activity_Hours': np.random.randint(0, 50, 300),
    'Cluster': np.random.choice([0, 1, 2], 300)
})

# 2. คำนวณ Cluster Mean และ Global Mean
cluster_avg = student_data.groupby('Cluster').mean()
global_avg = student_data.drop('Cluster', axis=1).mean()

# 3. คำนวณร้อยละความเบี่ยงเบน (Percentage Deviation)
deviation_df = ((cluster_avg - global_avg) / global_avg) * 100

# 4. สร้าง Heatmap
plt.figure(figsize=(8, 5))
# ใช้ cmap 'coolwarm' เพื่อให้สีแดงแสดงถึงค่าที่สูงกว่าค่าเฉลี่ย และสีน้ำเงินคือต่ำกว่าค่าเฉลี่ย
sns.heatmap(deviation_df, annot=True, fmt=".1f", cmap="coolwarm", center=0)
plt.title("Cluster Deviation Heatmap (% difference from Global Mean)")
plt.ylabel("Cluster ID")
plt.show()
```

ผลลัพธ์จากการรัน:

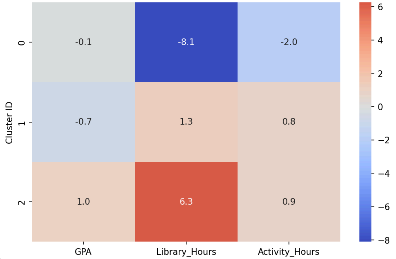

Deviation Heatmap

จากการใช้ `cmap="coolwarm"` ร่วมกับการกำหนด `center=0` เราสามารถตีความได้ทันทีว่า: * **สีแดงเข้ม:** ตัวแปรนั้นในกลุ่มดังกล่าว มีค่าสูงกว่าค่าเฉลี่ยของนักศึกษาทั้งหมดอย่างมีนัยสำคัญ * **สีน้ำเงินเข้ม:** ตัวแปรนั้นในกลุ่มดังกล่าว มีค่าต่ำกว่าค่าเฉลี่ยของนักศึกษาทั้งหมดอย่างมีนัยสำคัญ * **สีขาว/สีอ่อน:** ตัวแปรนั้นมีค่าใกล้เคียงกับค่าเฉลี่ยรวม ไม่ใช่ลักษณะเด่นของกลุ่ม

Cluster Drivers (ปัจจัยหลักที่กำหนดกลุ่ม)

ในชุดข้อมูลที่มีมิติสูง (High-dimensional data) ซึ่งมีตัวแปรหลายสิบหรือหลายร้อยตัวแปร ตัวแปรทุกตัวไม่ได้มีส่วนสำคัญเท่ากันในการแบ่งกลุ่มข้อมูล (James et al., 2023) การหาปัจจัยหลักที่กำหนดกลุ่ม (Cluster Drivers) คือการค้นหาว่าตัวแปรใดมีอิทธิพลมากที่สุดที่ทำให้อัลกอริทึมตัดสินใจแยกข้อมูลออกเป็นกลุ่มต่างๆ

เทคนิคที่ได้รับความนิยมและมีประสิทธิภาพสูงคือ การใช้โมเดลการเรียนรู้แบบมีผู้สอน (Supervised Learning) ประเภท Tree-based model เช่น Decision Tree หรือ Random Forest โดยกำหนดให้: * **Features (*X*):** ข้อมูลตัวแปรดั้งเดิมทั้งหมด * **Target (*y*):** ป้ายกำกับกลุ่ม (Cluster Labels) ที่ได้จากอัลกอริทึม Clustering

จากนั้นทำการฝึกสอน (Train) โมเดล และสกัดค่า **Feature Importance** ออกมา ตัวแปรที่มีค่า Importance สูงสุด คือปัจจัยหลัก (Drivers) ที่อธิบายความแตกต่างของกลุ่มได้ดีที่สุด

ตัวอย่างในบริบทสาธารณสุข: โรงพยาบาลแห่งหนึ่งทำการจัดกลุ่มผู้ป่วยโรคเบาหวาน โดยมีตัวแปรเช่น อายุ (Age), ดัชนีมวลกาย (BMI), ระดับน้ำตาลในเลือด (Glucose), ความดันโลหิต (Blood_Pressure), และระดับคอเลสเตอรอล (Cholesterol)

```
from sklearn.ensemble import RandomForestClassifier
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

# 1. สร้างข้อมูลจำลองผู้ป่วย
np.random.seed(42)
X_health = pd.DataFrame({
    'Age': np.random.randint(30, 80, 500),
    'BMI': np.random.uniform(18.5, 35.0, 500),
    'Glucose': np.random.randint(80, 200, 500),
    'Blood_Pressure': np.random.randint(80, 140, 500),
    'Cholesterol': np.random.randint(150, 300, 500)
})
# สมมติว่าจัดกลุ่มได้ 3 กลุ่ม
y_cluster = np.random.choice([0, 1, 2], 500)

# 2. สร้างและฝึกสอนโมเดล Random Forest
rf_model = RandomForestClassifier(n_estimators=100, random_state=42)
rf_model.fit(X_health, y_cluster)

# 3. ดึงค่า Feature Importance
feature_importances = pd.DataFrame({
    'Feature': X_health.columns,
    'Importance': rf_model.feature_importances_
}).sort_values(by='Importance', ascending=False)

# 4. แสดงผลลัพธ์ด้วย Bar Chart
plt.figure(figsize=(8, 4))
sns.barplot(x='Importance', y='Feature', data=feature_importances, palette='viridis')
plt.title("Cluster Drivers (Feature Importance)")
plt.xlabel("Importance Score")
plt.ylabel("Health Metrics")
plt.show()
```

ผลลัพธ์จากการรัน:

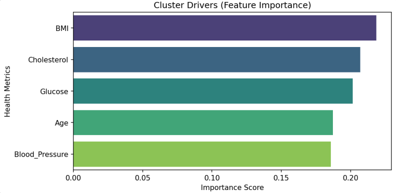

Cluster Drivers

```
      Feature  Importance
```

```
           BMI    0.218585
   Cholesterol    0.207083
       Glucose    0.201449
           Age    0.187215
Blood_Pressure    0.185669
```

หากผลลัพธ์แสดงให้เห็นว่า `Glucose` และ `BMI` มีค่า Importance Score รวมกันเกิน 70% ผู้วิเคราะห์สามารถสรุปได้ว่า ระดับน้ำตาลและดัชนีมวลกาย เป็นปัจจัยหลัก (Key Drivers) ที่แบ่งแยกประเภทของผู้ป่วยในชุดข้อมูลนี้ ซึ่งช่วยลดภาระทางการแพทย์ในการพิจารณาตัวแปรที่ไม่มีนัยสำคัญ

การตั้งชื่อกลุ่ม (Naming Clusters)

ขั้นตอนสุดท้ายของ Cluster Profiling คือการสังเคราะห์ข้อมูลจากการวิเคราะห์ Centroid, Heatmap และ Drivers เพื่อตั้งชื่อให้กับแต่ละกลุ่ม (Naming Clusters) การตั้งชื่อที่ดีต้องสะท้อนถึงลักษณะเด่นของกลุ่ม เข้าใจง่าย และสามารถนำไปใช้สื่อสารกับผู้มีส่วนได้ส่วนเสีย (Stakeholders) ที่ไม่ได้เป็นผู้เชี่ยวชาญด้านข้อมูลได้ทันที (Grus, 2019)

หลักการตั้งชื่อกลุ่มที่ดี: 1. **เน้นพฤติกรรมหรือคุณลักษณะเด่น:** ใช้คำคุณศัพท์หรือคำนามที่อธิบายตัวแปรที่เป็น Driver หลัก 2. **หลีกเลี่ยงชื่อเชิงลบเกินความจำเป็น:** หากเป็นบริบทลูกค้า ควรใช้คำที่เป็นกลางหรือมุ่งเน้นการแก้ปัญหา 3. **กระชับและจดจำง่าย:** คล้ายกับการสร้าง Persona ในทางการตลาด

ตารางตัวอย่างการตั้งชื่อกลุ่ม (สังเคราะห์จากข้อมูล E-commerce ใน Section 11.4.1):

Cluster ID	ลักษณะเด่นที่พบจากการทำ Profiling (Insights)	ปัจจัยหลัก (Drivers)	การตั้งชื่อกลุ่ม (Cluster Name)	กลยุทธ์ที่นำเสนอ (Actionable Strategy)
0	ซื้อไม่บ่อย ยอดใช้จ่ายปานกลาง เพิ่งเข้ามาซื้อไม่นาน	Recency (ต่ำ), Frequency (กลาง)	**กลุ่มลูกค้าทั่วไป (Standard)**	ส่งโปรโมชันกระตุ้นให้เกิดการซื้อซ้ำในหมวดสินค้าที่เกี่ยวข้อง
1	ขาดการติดต่อไปนานมาก ยอดใช้จ่ายและความถี่ต่ำมาก	Recency (สูงมาก)	**กลุ่มลูกค้าที่กำลังจะสูญเสีย (At-Risk / Churned)**	ส่งอีเมลแคมเปญลดราคาพิเศษแบบจำกัดเวลาเพื่อดึงดูดกลับมา
2	ซื้อบ่อยมาก ยอดใช้จ่ายสูงมาก เพิ่งซื้อไปไม่นาน	Monetary (สูง), Frequency (สูง)	**กลุ่มลูกค้าชั้นดี (Champions / VIP)**	มอบสิทธิพิเศษ (Loyalty Program) และการบริการระดับพรีเมียม

การตั้งชื่อกลุ่มเปรียบเสมือนการแปลภาษาคณิตศาสตร์ให้กลายเป็นภาษาธุรกิจ ซึ่งเป็นทักษะที่ Data Scientist จำเป็นต้องมี เพื่อให้ผลลัพธ์จากการทำ Machine Learning ถูกนำไปประยุกต์ใช้ในการตัดสินใจระดับองค์กรได้อย่างแท้จริง

สรุปประเด็นสำคัญ

- **Cluster Profiling** คือกระบวนการทำความเข้าใจลักษณะและพฤติกรรมของข้อมูลในแต่ละกลุ่ม เพื่อเปลี่ยนตัวเลข Cluster Labels ให้เป็นข้อมูลเชิงลึก (Insights) ที่นำไปใช้ประโยชน์ได้
- **Centroid Analysis** และ **Deviation Heatmap** ใช้สำหรับเปรียบเทียบค่าเฉลี่ยของตัวแปรในกลุ่มกับค่าเฉลี่ยรวมระดับประชากร โดย Heatmap ช่วยให้มองเห็นความแตกต่างในรูปแบบภาพที่ชัดเจนขึ้น
- **Cluster Drivers** สามารถค้นหาได้โดยใช้โมเดล Supervised Learning (เช่น Random Forest) มาทำนาย Cluster Label เพื่อหา Feature Importance
- **การตั้งชื่อกลุ่ม (Naming Clusters)** เป็นศิลปะในการสื่อสารข้อมูล (Data Storytelling) โดยต้องตั้งชื่อให้สะท้อนถึงปัจจัยหลักและเข้าใจง่ายสำหรับผู้ใช้งานทางธุรกิจ

คำถามท้าย Section

1. หากนักศึกษาใช้ K-Means จัดกลุ่มข้อมูลลูกค้าได้ 5 กลุ่ม แต่พบว่าค่าเฉลี่ยของตัวแปรทุกตัวใน 5 กลุ่มนั้นแทบจะไม่แตกต่างจากค่าเฉลี่ยรวม (Global Mean) เลย นักศึกษาคิดว่าเกิดปัญหาอะไรขึ้นในกระบวนการ Clustering และควรแก้ไขอย่างไร?
2. แม้ว่า Deviation Heatmap จะคำนวณร้อยละความเบี่ยงเบนได้ชัดเจน แต่ในกรณีที่ตัวแปรบางตัวมีค่าเฉลี่ยรวม (Global Mean) ใกล้ศูนย์หรือเป็นศูนย์ การใช้สมการ $\frac{ClusterMean - GlobalMean}{GlobalMean}$ จะเกิดปัญหาใด และนักศึกษาจะเสนอวิธีทางคณิตศาสตร์อื่นใดในการสร้าง Heatmap เพื่อหลีกเลี่ยงปัญหานี้?
3. พิจารณาข้อมูลนักศึกษามหาวิทยาลัย หากกลุ่มที่ 1 มีลักษณะเด่นคือ “ชั่วโมงกิจกรรมสูงมาก เกรดเฉลี่ยต่ำ และชั่วโมงห้องสมุดต่ำ” ในขณะที่กลุ่มที่ 2 คือ “เกรดเฉลี่ยสูงมาก ชั่วโมงกิจกรรมต่ำ ชั่วโมงห้องสมุดสูง” ให้นักศึกษาตั้งชื่อกลุ่มทั้งสอง พร้อมเสนอแนะแนวทางที่กองกิจการนักศึกษาควรใช้ในการดูแลนักศึกษาแต่ละกลุ่ม

การทดสอบทางสถิติสำหรับ Clusters

ภายหลังจากการประยุกต์ใช้อัลกอริทึมการจัดกลุ่ม (Clustering Algorithms) เช่น K-Means หรือ DBSCAN เพื่อแบ่งข้อมูลออกเป็นกลุ่มต่าง ๆ แล้ว คำถามสำคัญที่นักวิทยาการข้อมูลต้องตอบให้ได้คือ “กลุ่มข้อมูลที่ถูกสร้างขึ้นมีความแตกต่างกันอย่างมีนัยสำคัญทางสถิติหรือไม่?” เนื่องจากการจัดกลุ่มเป็นกระบวนการเรียนรู้แบบไม่มีผู้สอน (Unsupervised Learning) อัลกอริทึมจะพยายามแบ่งกลุ่มตามโครงสร้างทางคณิตศาสตร์เสมอแม้ว่าข้อมูลนั้นอาจไม่มีโครงสร้างกลุ่มที่แท้จริงอยู่เลยก็ตาม การทดสอบทางสถิติ (Statistical Testing) จึงเป็นเครื่องมือสำคัญในการยืนยันคุณลักษณะ (Profiling) ของแต่ละ Cluster ว่ามีความแตกต่างกันจริงในเชิงประจักษ์

การทดสอบสมมติฐานทางสถิติเพื่อเปรียบเทียบความแตกต่างระหว่างกลุ่ม จะพิจารณาตัวแปรอิสระ (Features) ที่ใช้ในการจัดกลุ่ม หรือตัวแปรภายนอกอื่น ๆ โดยมีขั้นตอนและวิธีการที่ต้องพิจารณาดังต่อไปนี้

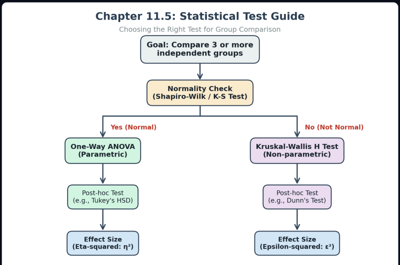
Chapter 11.5: Statistical Test Guide
Choosing the Right Test for Group Comparison
Goal: Compare 3 or more independent groups
Normality Check (Shapiro-Wilk / K-S Test)
Yes (Normal)
No (Not Normal)
One-Way ANOVA (Parametric)
Kruskal-Wallis H Test (Non-parametric)
Post-hoc Test (e.g., Tukey's HSD)
Post-hoc Test (e.g., Dunn's Test)
Effect Size (Eta-squared: η²)
Effect Size (Epsilon-squared: ε²)

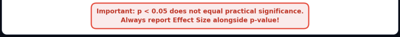

Important: $p < 0.05$ does not equal practical significance.
Always report Effect Size alongside p-value!

Statistical Test Guide

การตรวจสอบการแจกแจงแบบปกติ (Normality Check) ด้วย Shapiro-Wilk Test

ก่อนที่จะเลือกใช้สถิติทดสอบใด ๆ นักวิทยาการข้อมูลจำเป็นต้องตรวจสอบข้อตกลงเบื้องต้น (Assumptions) ของข้อมูลเสียก่อน ข้อตกลงที่สำคัญที่สุดคือ การแจกแจงของข้อมูล (Data Distribution) ว่ามีการแจกแจงแบบปกติ (Normal Distribution) หรือไม่ ซึ่งจะนำไปสู่การตัดสินใจเลือกใช้สถิติแบบพารามิเตอร์ (Parametric) หรือ สถิติแบบไร้พารามิเตอร์ (Non-parametric)

การทดสอบ Shapiro-Wilk (Shapiro & Wilk, 1965) เป็นวิธีที่ได้รับการยอมรับว่ามีประสิทธิภาพสูงในการตรวจสอบการแจกแจงแบบปกติ โดยมีสมมติฐานการทดสอบดังนี้: * H_0 **(Null Hypothesis):** ข้อมูลมีการแจกแจงแบบปกติ * H_a **(Alternative Hypothesis):** ข้อมูลไม่มีการแจกแจงแบบปกติ

หากค่า p-value ที่คำนวณได้น้อยกว่าระดับนัยสำคัญ (α) ที่กำหนด (โดยทั่วไปใช้ 0.05) จะปฏิเสธ H_0 และสรุปว่าข้อมูลไม่ได้แจกแจงแบบปกติ

ข้อควรระวัง: ในงาน Data Science ที่มีขนาดตัวอย่าง (Sample Size) ขนาดใหญ่มาก การทดสอบ Shapiro-Wilk มักจะให้ผลปฏิเสธ H_0 เสมอ แม้ข้อมูลจะเบี่ยงเบนจากโค้งปกติเพียงเล็กน้อย ดังนั้นควรพิจารณาควบคู่กับการดูแผนภาพ Q-Q Plot หรือ Histogram เสมอ

การเปรียบเทียบความแตกต่างระหว่างกลุ่ม: ANOVA vs Kruskal-Wallis

เมื่อทราบถึงลักษณะการแจกแจงของข้อมูลแล้ว ขั้นตอนต่อไปคือการทดสอบความแตกต่างของค่ากลางระหว่าง Clusters ซึ่งมี 2 วิธีหลักที่นิยมใช้

1. Analysis of Variance (ANOVA) ANOVA เป็นสถิติแบบพารามิเตอร์ (Parametric Test) ที่ใช้เปรียบเทียบค่าเฉลี่ย (Mean) ของกลุ่มตัวอย่างตั้งแต่ 3 กลุ่มขึ้นไป * **ข้อตกลงเบื้องต้น:** ข้อมูลต้องมีการแจกแจงแบบปกติ (Normality) และความแปรปรวนของแต่ละกลุ่มต้องเท่ากัน (Homogeneity of Variances) * **บริบทการใช้งาน:** เหมาะกับข้อมูลที่มีความต่อเนื่องและไม่มีค่าผิดปกติ (Outliers) รุนแรง เช่น คะแนนสอบของนักศึกษามหาวิทยาลัยขอนแก่นในแต่ละกลุ่มการเรียน

2. Kruskal-Wallis H-test Kruskal-Wallis เป็นสถิติแบบไร้พารามิเตอร์ (Non-parametric Test) ซึ่งเป็นทางเลือกแทน ANOVA เมื่อข้อมูลไม่ผ่านข้อตกลงเบื้องต้น วิธีนี้จะไม่เปรียบเทียบค่าเฉลี่ย แต่จะแปลงข้อมูลทั้งหมดเป็นลำดับที่ (Ranks) แล้วเปรียบเทียบค่ามัธยฐาน (Median) หรือการกระจายของลำดับที่แทน * **ข้อตกลงเบื้องต้น:** ไม่ต้องการการแจกแจงแบบปกติ ทนทานต่อค่า Outliers * **บริบทการใช้งาน:** เหมาะกับข้อมูลทางธุรกิจที่มีความเบ้ (Skewness) สูง เช่น ข้อมูลยอดการใช้จ่ายผ่านบัตรเครดิตของธนาคารพาณิชย์ หรือ ยอดสั่งซื้อสินค้าบนแพลตฟอร์ม E-commerce ซึ่งมักจะมีผู้ใช้งานจำนวนน้อยที่มียอดใช้จ่ายสูงมาก (Right-skewed)

คุณลักษณะ	ANOVA (Parametric)	Kruskal-Wallis (Non-parametric)
สิ่งที่เปรียบเทียบ	ค่าเฉลี่ย (Mean)	ค่ามัธยฐาน (Median) / ลำดับที่ (Ranks)
ข้อตกลงเรื่องการแจกแจง	ต้องเป็นโค้งปกติ (Normal Distribution)	ไม่จำเป็น (Distribution-free)
ผลกระทบจาก Outliers	อ่อนไหวสูง (Highly Sensitive)	ทนทาน (Robust)
ความเหมาะสมกับข้อมูล Big Data	ปานกลาง (มักผิดข้อตกลงเบื้องต้น)	สูง (เหมาะสมกับข้อมูลจริงที่มักเบ้)

ขนาดของอิทธิพล (Effect Size: η^2)

การทดสอบสมมติฐานทางสถิติ (เช่น ANOVA) จะให้ค่า p-value ซึ่งบอกได้เพียงว่า Clusters มีความแตกต่างกันหรือไม่ แต่ไม่ได้บอกว่าความแตกต่างนั้น “มากน้อยเพียงใด” การวัดขนาดของอิทธิพล (Effect Size) จึงเข้ามามีบทบาทสำคัญ

สำหรับ ANOVA ค่า Effect Size ที่นิยมใช้คือ **Eta-squared (η^2)** ซึ่งคำนวณจากสัดส่วนของความแปรปรวนที่อธิบายได้ด้วยตัวแปรจัดกลุ่ม (Clusters) ต่อความแปรปรวนทั้งหมดของข้อมูล

$$\eta^2 = \frac{SS_{between}}{SS_{total}}$$

โดยที่: * $SS_{between}$ คือ ผลรวมกำลังสองของความแตกต่างระหว่างกลุ่ม (Sum of Squares Between) * SS_{total} คือ ผลรวมกำลังสองทั้งหมด (Total Sum of Squares)

เกณฑ์การแปลผล η^2 (Cohen, 1988): * $\eta^2 \approx 0.01$: ขนาดอิทธิพลน้อย (Small effect) * $\eta^2 \approx 0.06$: ขนาดอิทธิพลปานกลาง (Medium effect) * $\eta^2 \approx 0.14$ ขึ้นไป : ขนาดอิทธิพลมาก (Large effect)

ตัวอย่าง: หากพบว่าตัวแปร “จำนวนครั้งที่เข้าใช้งานแอปพลิเคชันธนาคาร” มีค่า $\eta^2 = 0.45$ เมื่อเทียบระหว่าง Clusters หมายความว่า การแบ่งกลุ่มลูกค้าสามารถอธิบายความแตกต่างของการเข้าใช้งานแอปพลิเคชันได้ถึง 45% ซึ่งถือว่าเป็นตัวแปรที่แยกความแตกต่างของกลุ่มได้อย่างมีประสิทธิภาพสูง

p-value ≠ Practical Significance (นัยสำคัญทางสถิติ ไม่เท่านัยสำคัญทางปฏิบัติ)

ประเด็นที่นักวิทยาการข้อมูลมักตกหลุมพรางคือ การยึดติดกับค่า p-value มากเกินไป (Wasserstein & Lazar, 2016) ในยุคของ Big Data ที่ชุดข้อมูลมีขนาดนับล้านแถว (Large N) การทดสอบทางสถิติแทบทุกชนิดจะให้ค่า $p\text{-value} < 0.05$ เสมอ แม้ว่าความแตกต่างระหว่างกลุ่มจะมีเพียงเล็กน้อยก็ตาม

นัยสำคัญทางสถิติ (Statistical Significance): บอกว่าความแตกต่างที่พบ ไม่ได้เกิดจากความบังเอิญ (พิจารณาจาก p-value) **นัยสำคัญทางปฏิบัติ (Practical Significance):** บอกว่าความแตกต่างนั้น มีคุณค่าหรือมีประโยชน์ต่อการตัดสินใจทางธุรกิจหรือไม่ (พิจารณาจาก Effect Size และบริบททางธุรกิจ)

ตัวอย่างในบริบท E-commerce ของประเทศไทย: สมมติว่ามีการจัดกลุ่มลูกค้าแพลตฟอร์ม E-commerce ออกเป็น 2 กลุ่ม (กลุ่ม A มี 500,000 คน, กลุ่ม B มี 500,000 คน) เมื่อทดสอบความแตกต่างของยอดสั่งซื้อเฉลี่ยต่อเดือน พบว่า: * กลุ่ม A มียอดสั่งซื้อเฉลี่ย 1,500 บาท * กลุ่ม B มียอดสั่งซื้อเฉลี่ย 1,505 บาท * ผลการทดสอบทางสถิติได้ค่า $p\text{-value} = 0.001$ (มีนัยสำคัญทางสถิติ)

แม้ p-value จะบ่งชี้ว่ากลุ่ม A และ B ต่างกันอย่างแน่นอน แต่ในทางปฏิบัติ (Practical Significance) ยอดใช้จ่ายที่ต่างกันเพียง 5 บาท อาจไม่คุ้มค่าต่อการที่ทีมวิเคราะห์การตลาดจะต้องออกแบบแคมเปญส่งเสริมการขาย (Marketing Campaign) แยกเฉพาะสำหรับสองกลุ่มนี้ ในกรณีนี้ การพิจารณา Effect Size (η^2) จะพบว่ามีค่าเข้าใกล้ 0 ซึ่งยืนยันว่าการแบ่งกลุ่มนี้ไม่มีประโยชน์ในทางปฏิบัติ

ตัวอย่างการประยุกต์ใช้ด้วย Python

พิจารณาสถานการณ์จำลอง: การจัดกลุ่มลูกค้าของธนาคารพาณิชย์ในประเทศไทย เพื่อวิเคราะห์พฤติกรรมการทำธุรกรรมผ่านระบบ PromptPay โดยเราทำการจัดกลุ่มด้วย K-Means และต้องการทดสอบว่าตัวแปร `transaction_amount` (ยอดเงินโอนเฉลี่ย) มีความแตกต่างกันในแต่ละกลุ่มอย่างมีนัยสำคัญหรือไม่

```
import pandas as pd
import numpy as np
from scipy import stats
from sklearn.cluster import KMeans
```

```python
# 1. สร้างชุดข้อมูลจำลอง (Synthetic Data) ของลูกค้าธนาคาร 1000 ราย
np.random.seed(42)
data = {
    'customer_id': range(1, 1001),
    # กลุ่มลูกค้าทั่วไป โอนเงินจำนวนน้อยแต่บ่อย
    'transaction_amount': np.concatenate([
        np.random.normal(500, 100, 600),
        # กลุ่มพ่อค้าแม่ค้าออนไลน์ โอนเงินจำนวนปานกลาง
        np.random.normal(3000, 500, 300),
        # กลุ่มธุรกิจ SME โอนเงินจำนวนมาก
        np.random.normal(15000, 2000, 100)
    ])
}
df = pd.DataFrame(data)

# 2. ทำการจัดกลุ่มด้วย K-Means (สมมติว่าจัดเป็น 3 กลุ่ม)
X = df[['transaction_amount']]
kmeans = KMeans(n_clusters=3, random_state=42, n_init=10)
df['cluster'] = kmeans.fit_predict(X)

print("ค่าเฉลี่ยธุรกรรมแต่ละกลุ่ม:")
print(df.groupby('cluster')['transaction_amount'].mean().round(2))
print("-" * 40)

# 3. Normality Check ด้วย Shapiro-Wilk Test
# สุ่มตัวอย่างมาทดสอบเพื่อหลีกเลี่ยงผลกระทบจาก Large N
sample_data = df['transaction_amount'].sample(100, random_state=42)
stat, p_shapiro = stats.shapiro(sample_data)
print(f"Shapiro-Wilk Test: p-value = {p_shapiro:.4f}")
if p_shapiro < 0.05:
    print("สรุป: ข้อมูลไม่มีการแจกแจงแบบปกติ (ควรใช้ Non-parametric test)")
else:
    print("สรุป: ข้อมูลมีการแจกแจงแบบปกติ")
print("-" * 40)

# 4. ทดสอบความแตกต่างระหว่างกลุ่มด้วย Kruskal-Wallis (เนื่องจากข้อมูลไม่ปกติ)
cluster_0 = df[df['cluster'] == 0]['transaction_amount']
cluster_1 = df[df['cluster'] == 1]['transaction_amount']
cluster_2 = df[df['cluster'] == 2]['transaction_amount']

h_stat, p_kruskal = stats.kruskal(cluster_0, cluster_1, cluster_2)
print(f"Kruskal-Wallis Test: H-statistic = {h_stat:.2f}, p-value = {p_kruskal:.4e}")

# 5. การคำนวณ Effect Size (Epsilon-squared สำหรับ Kruskal-Wallis)
# สูตร e^2 = H / ((n^2 - 1) / (n + 1)) = H / (n - 1)
n = len(df)
epsilon_sq = h_stat / (n - 1)
print(f"Effect Size (Epsilon-squared): {epsilon_sq:.4f}")

if epsilon_sq < 0.01:
    print("สรุป: ขนาดอิทธิพลน้อย (Small effect) - อาจไม่มีนัยสำคัญทางปฏิบัติ")
elif epsilon_sq < 0.06:
    print("สรุป: ขนาดอิทธิพลปานกลาง (Medium effect)")
else:
    print("สรุป: ขนาดอิทธิพลมาก (Large effect) - กลุ่มมีความแตกต่างกันอย่างชัดเจนในทางปฏิบัติ")
```

ผลลัพธ์จากการรัน:

```
ค่าเฉลี่ยธุรกรรมแต่ละกลุ่ม:
cluster
0      502.52
1    15055.71
2     3050.35
----------------------------------------
Shapiro-Wilk Test: p-value = 0.0000
สรุป: ข้อมูลไม่มีการแจกแจงแบบปกติ (ควรใช้ Non-parametric test)
----------------------------------------
Kruskal-Wallis Test: H-statistic = 753.62, p-value = 2.2618e-164
Effect Size (Epsilon-squared): 0.7544
สรุป: ขนาดอิทธิพลมาก (Large effect) - กลุ่มมีความแตกต่างกันอย่างชัดเจนในทางปฏิบัติ
```

ผลลัพธ์ที่คาดหวังจากการรันโค้ด: โค้ดจะแสดงให้เห็นว่าข้อมูลทางการเงินมักไม่มีการแจกแจงแบบปกติ (Shapiro-Wilk $p < 0.05$) การใช้ Kruskal-Wallis จะยืนยันว่าแต่ละกลุ่มมีความแตกต่างกัน ($p \approx 0.0000$) และเมื่อคำนวณ Effect Size จะพบว่ามีค่าสูงมาก บ่งชี้ว่าการจัดกลุ่มนี้มีประโยชน์ในการนำไปใช้วางแผนการตลาดสำหรับธนาคารในทางปฏิบัติ (Practical Significance)

สรุปประเด็นสำคัญ

- **การตรวจสอบข้อตกลงเบื้องต้นเป็นสิ่งจำเป็น:** ก่อนทดสอบสมมติฐาน ต้องใช้ Shapiro-Wilk test เพื่อตรวจสอบความปกติของข้อมูล ซึ่งจะนำไปสู่การเลือกใช้ ANOVA (พาราเมตอร์) หรือ Kruskal-Wallis (ไร้พาราเมตอร์)
- **ข้อมูลจริงมักไม่สมบูรณ์:** ในงาน Data Science ข้อมูลทางธุรกิจ (เช่น ยอดเงิน, จำนวนครั้งการซื้อ) มักมีการกระจายตัวแบบเบ้ (Skewed) การใช้ Kruskal-Wallis จึงมีความทนทาน (Robust) และเหมาะสมกว่า ANOVA ในหลายสถานการณ์
- **อย่าเชื่อเพียง p-value:** ค่า p-value บอกเพียงว่ากลุ่มแตกต่างกันทางสถิติหรือไม่ แต่ขนาดของอิทธิพล (Effect Size เช่น η^2) เป็นตัวชี้วัดว่าความแตกต่างนั้นมีขนาดใหญ่เพียงพอที่จะนำไปใช้ประโยชน์ได้จริงหรือไม่
- **นัยสำคัญทางปฏิบัติ (Practical Significance) สำคัญที่สุด:** การตั้งคำถามว่า “ความแตกต่างนี้สร้างมูลค่าทางธุรกิจได้หรือไม่” เป็นสิ่งที่นักวิทยาการข้อมูลต้องประเมินควบคู่กับผลลัพธ์ทางคณิตศาสตร์เสมอ

คำถามท้าย Section

1. หากท่านได้รับมอบหมายให้วิเคราะห์กลุ่มผู้ป่วยโรคเบาหวานของโรงพยาบาลแห่งหนึ่ง (จำนวน 50,000 คน) โดยมีตัวแปรคือ “ระยะเวลาที่รอรับการรักษา (นาที)” เมื่อทำการทดสอบ Shapiro-Wilk พบว่า p-value = 0.0001 ท่านจะเลือกใช้สถิติทดสอบใดในการเปรียบเทียบระยะเวลาการรอคอยระหว่างกลุ่มผู้ป่วย 4 กลุ่ม พร้อมอธิบายเหตุผล
2. จงอธิบายความแตกต่างระหว่าง “นัยสำคัญทางสถิติ (Statistical Significance)” และ “นัยสำคัญทางปฏิบัติ (Practical Significance)” พร้อมยกตัวอย่างสถานการณ์ในระบบการลงทะเบียนเรียนของมหาวิทยาลัยขอนแก่นที่ผลลัพธ์มีนัยสำคัญทางสถิติ แต่ไม่มีนัยสำคัญทางปฏิบัติ

Storytelling และ Domain Expert Collaboration

การจัดกลุ่มข้อมูล (Clustering) เป็นเทคนิคการเรียนรู้แบบไม่มีผู้สอน (Unsupervised Learning) ซึ่งอัลกอริทึมจะค้นหาโครงสร้างและรูปแบบทางคณิตศาสตร์ที่ซ่อนอยู่ในข้อมูลโดยปราศจากฉลาก (Labels) กำกับล่วงหน้า แม้ว่าอัลกอริทึมอย่าง K-Means หรือ DBSCAN จะสามารถจัดกลุ่มข้อมูลได้อย่างมีประสิทธิภาพในเชิงตัวเลข แต่ผลลัพธ์ที่ได้มักจะเป็นเพียงตัวเลขระบุกลุ่ม (เช่น Cluster 0, Cluster 1) ซึ่งปราศจากความหมายในบริบทของโลกความเป็นจริง (Real-world Context)

ความท้าทายสูงสุดของกระบวนการ Clustering จึงไม่ใช่การเขียนโค้ดเพื่อสร้างโมเดล แต่คือการตีความหมายของกลุ่มข้อมูลเหล่านั้น และนำเสนอให้ผู้มีอำนาจตัดสินใจเข้าใจเพื่อนำไปสร้างมูลค่าทางธุรกิจ (Business Value) กระบวนการนี้จำเป็นต้องอาศัยสององค์ประกอบหลัก ได้แก่ การทำงานร่วมกับผู้เชี่ยวชาญเฉพาะทาง (Domain Expert Collaboration) และทักษะการเล่าเรื่องจากข้อมูล (Data Storytelling)

บทบาทของ Data Scientist และ Domain Expert

ในการดำเนินโครงงานวิทยาการข้อมูล การทำงานแยกส่วนกันระหว่างผู้เชี่ยวชาญด้านข้อมูลและผู้เชี่ยวชาญในสายงานธุรกิจมักนำไปสู่โมเดลที่ไม่สามารถใช้งานได้จริง (Unusable Models) การบูรณาการความรู้ระหว่าง Data Scientist และ Domain Expert จึงเป็นสิ่งจำเป็นอย่างยิ่ง (Indispensable)

Data Scientist (นักวิทยาศาสตร์ข้อมูล): มีหน้าที่หลักในการจัดการข้อมูล เลือกใช้อัลกอริทึมที่เหมาะสม ปรับแต่งพารามิเตอร์ (Hyperparameter Tuning) และประเมินประสิทธิภาพของโมเดลในเชิงปริมาณ (Quantitative Evaluation) เช่น การคำนวณ Silhouette Score หรือ Davies-Bouldin Index

Domain Expert (ผู้เชี่ยวชาญเฉพาะทาง): คือบุคคลที่มีความรู้ความเข้าใจอย่างลึกซึ้งในธุรกิจหรือศาสตร์นั้นๆ เช่น แพทย์ผู้เชี่ยวชาญในโรงพยาบาล ผู้จัดการฝ่ายการตลาดของแพลตฟอร์ม E-commerce หรือนักวิชาการศึกษาของมหาวิทยาลัย มีหน้าที่ประเมินผลลัพธ์ในเชิงคุณภาพ (Qualitative Evaluation) และตรวจสอบความสมเหตุสมผลของกลุ่มข้อมูล

ความรับผิดชอบ	Data Scientist	Domain Expert
การเตรียมข้อมูล (Data Preparation)	จัดการ Missing Values, Scaling, Encoding	ระบุตัวแปร (Features) ที่มีความสำคัญต่อธุรกิจ
การเลือกโมเดล (Model Selection)	เลือกใช้อัลกอริทึมที่เหมาะสมกับลักษณะการกระจายตัวของข้อมูล	กำหนดข้อจำกัดทางธุรกิจ (เช่น จำนวนกลุ่มที่ทีมการตลาดสามารถดูแลได้จริง)
การประเมินผล (Evaluation)	ประเมินด้วยตัวชี้วัดทางสถิติ (Statistical Metrics)	ประเมินความหมายและความสามารถในการนำไปปฏิบัติจริง (Actionability)
การนำไปใช้งาน (Deployment)	สร้าง Data Pipeline และ Automate กระบวนการ	ออกแบบกลยุทธ์หรือแคมเปญให้สอดคล้องกับแต่ละกลุ่มข้อมูล

ตัวอย่างในบริบทมหาวิทยาลัยขอนแก่น: พิจารณาโครงงานการจัดกลุ่มนักศึกษาที่มีความเสี่ยงในการพ้นสภาพ (Dropout Risk) Data Scientist (นักศึกษาคอมพิวเตอร์) ใช้ K-Means จัดกลุ่มข้อมูลผลการเรียนและพฤติกรรมการเข้าเรียน ได้ผลลัพธ์เป็น 3 กลุ่ม แต่ผู้ที่จะตีความได้ว่า “กลุ่มที่ 2 ซึ่งมีเกรดเฉลี่ยปานกลางแต่ขาดเรียนบ่อยในวิชาพื้นฐาน” คือกลุ่มที่มีปัญหาด้านการปรับตัวเข้ากับชีวิตมหาวิทยาลัย ไม่ใช่ปัญหาด้านสติปัญญา คือ Domain Expert ซึ่งได้แก่ อาจารย์ที่ปรึกษาหรือเจ้าหน้าที่กองบริการการศึกษา

การตรวจสอบความสมเหตุสมผลของกลุ่มข้อมูล (Validate Clusters)

การตรวจสอบกลุ่มข้อมูล (Cluster Validation) ในทางปฏิบัติไม่ได้สิ้นสุดที่การดูค่าทางคณิตศาสตร์ แต่ต้องผ่านกระบวนการ “Sanity Check” โดย Domain Expert เสมอ กระบวนการนี้ประกอบด้วยการตั้งคำถามสำคัญ 3 ประการ:

1. **Interpretability (ความสามารถในการตีความ):** แต่ละกลุ่มมีลักษณะเฉพาะที่สามารถอธิบายเป็นภาษามนุษย์ได้หรือไม่? หากมีกลุ่มที่ข้อมูลผสมปนเปจนหาจุดเด่นไม่ได้ อาจบ่งชี้ว่าจำนวน K ที่เลือกไม่เหมาะสม หรือเกิดจากการเลือก Features ที่มีสัญญาณรบกวน (Noise) มากเกินไป
2. **Distinctiveness (ความแตกต่างอย่างมีนัยสำคัญ):** กลุ่มข้อมูลมีความแตกต่างกันในมุมมองของธุรกิจหรือไม่? ในเชิงสถิติ Cluster A และ B อาจอยู่ห่างกัน แต่ในเชิงธุรกิจ หากทั้งสองกลุ่มต้องการกลยุทธ์การตลาดแบบเดียวกัน การรวมกลุ่ม (Merge) อาจเป็นทางเลือกที่ดีกว่า
3. **Actionability (ความสามารถในการนำไปขับเคลื่อนการกระทำ):** องค์กรสามารถดำเนินการบางอย่างกับกลุ่มข้อมูลนี้ได้หรือไม่?

ตัวอย่างในบริบทสาธารณสุข (Healthcare): โรงพยาบาลแห่งหนึ่งในภาคอีสานต้องการจัดกลุ่มผู้ป่วยโรคเบาหวานเพื่อจัดสรรทรัพยากรทางการแพทย์ Data Scientist พบว่า K=5 ให้ค่า Silhouette Score สูงสุด แต่เมื่อนำไปปรึกษาแพทย์ผู้เชี่ยวชาญ (Domain Expert) แพทย์ระบุว่าในทางคลินิก การดูแลผู้ป่วยเบาหวานแบ่งออกเป็นเพียง 3 ระดับหลัก (ควบคุมได้ดี, เริ่มมีภาวะแทรกซ้อน, วิกฤต) การแบ่งเป็น 5 กลุ่มทำให้เกิดความซ้ำซ้อนในการจัดสรรพยาบาลผู้ดูแล ในกรณีนี้ Data Scientist จะต้องยอมลดค่าทางสถิติลง และรันโมเดลใหม่ด้วย K=3 เพื่อให้เกิด Actionability ตามคำแนะนำของแพทย์

การนำเสนอผลลัพธ์ด้วย Storytelling (Customer Segmentation Storytelling)

เมื่อได้กลุ่มข้อมูลที่ผ่านการตรวจสอบจาก Domain Expert แล้ว ขั้นตอนต่อไปคือการสื่อสารผลลัพธ์ไปยังผู้บริหารระดับสูง (C-Level Executives) หรือผู้มีส่วนได้ส่วนเสีย (Stakeholders) ซึ่งมักไม่มีพื้นฐานด้านวิทยาการข้อมูล การนำเสนอด้วยค่า Silhouette Score หรือกราฟ Scatter Plot 3 มิติที่ซับซ้อนมักล้มเหลวในการสื่อสาร

ตามแนวคิดของ Knaflic (2015) การทำ Data Storytelling ที่มีประสิทธิภาพประกอบด้วย 3 องค์ประกอบ: บริบท (Context), ภาพนำเสนอ (Visual), และการเล่าเรื่อง (Narrative)

ในการทำ Clustering เทคนิคที่ทรงพลังที่สุดในการเล่าเรื่องคือ **การสร้างตัวแทนบุคคล (Persona Creation)** แทนที่จะเรียกกลุ่มข้อมูลว่า Cluster 0, 1, 2 เราจะตั้งชื่อกลุ่มให้สะท้อนถึงพฤติกรรมหลัก และบรรยายลักษณะราวกับว่ากลุ่มข้อมูลนั้นเป็นบุคคลที่มีชีวิตจริง

ตัวอย่างการสร้าง Persona สำหรับธุรกิจธนาคาร (Credit Card Customer Segmentation): สมมติว่าเราจัดกลุ่มข้อมูลลูกค้าบัตรเครดิตของธนาคารแห่งหนึ่งโดยใช้พฤติกรรมการใช้จ่าย (Spending Score) และรายได้ (Income) ได้เป็น 3 กลุ่ม

- **กลุ่มที่ 0 -> “กลุ่มสร้างเนื้อสร้างตัว” (First-Jobbers):** รายได้ระดับเริ่มต้นถึงปานกลาง แต่มีการใช้จ่ายผ่านบัตรในความถี่สูง (Transaction count สูง) มักใช้จ่ายกับร้านกาแฟ ซูเปอร์มาร์เก็ต และการเดินทางสาธารณะ
- **กลุ่มที่ 1 -> “กลุ่มมั่งคั่งเงียบ” (Conservative Wealth):** รายได้สูงมาก แต่มียอดการใช้จ่ายผ่านบัตรต่ำ มักใช้บัตรเฉพาะการซื้อประกันภัยหรือจ่ายค่ารักษาพยาบาล
- **กลุ่มที่ 2 -> “กลุ่มเสพติดไลฟ์สไตล์” (Lifestyle Shoppers):** รายได้ปานกลางถึงสูง มียอดใช้จ่ายสูงมาก มักใช้เต็มวงเงิน รูดซื้อสินค้าฟุ่มเฟือย ท่องเที่ยว และทานอาหารในห้างสรรพสินค้า

พิจารณาตัวอย่าง Code ด้านล่าง ซึ่งแสดงวิธีการวิเคราะห์ค่าเฉลี่ยของตัวแปรในแต่ละกลุ่ม เพื่อนำไปสร้าง Persona และนำเสนอผ่านกราฟแท่ง (Bar Chart) ที่เข้าใจง่าย

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.cluster import KMeans
```

```
# 1. สร้างข้อมูลจำลองลูกค้าบัตรเครดิต (รายได้, ยอดใช้จ่ายต่อเดือน, ความถี่การใช้บัตร)
np.random.seed(42)
data = {
    'Income_THB': np.concatenate([np.random.normal(25000, 5000, 100),   # กลุ่มสร้างเนื้อสร้างตัว
                                  np.random.normal(120000, 20000, 100), # กลุ่มมั่งคั่งเงียบ
                                  np.random.normal(60000, 15000, 100)]),# กลุ่มเสพติดไลฟ์สไตล์
    'Monthly_Spend_THB': np.concatenate([np.random.normal(15000, 3000, 100),
                                         np.random.normal(10000, 4000, 100),
                                         np.random.normal(45000, 8000, 100)]),
    'Transactions_Per_Month': np.concatenate([np.random.normal(30, 5, 100),
                                              np.random.normal(5, 2, 100),
                                              np.random.normal(20, 5, 100)])
}
df = pd.DataFrame(data)

# 2. ทำการจัดกลุ่มด้วย K-Means
kmeans = KMeans(n_clusters=3, random_state=42, n_init=10)
df['Cluster'] = kmeans.fit_predict(df)

# 3. เตรียมข้อมูลสำหรับการทำ Storytelling (หาค่าเฉลี่ยของแต่ละกลุ่ม)
cluster_summary = df.groupby('Cluster').mean().round(2)

# กำหนดชื่อ Persona ให้แต่ละ Cluster (สมมติว่าวิเคราะห์ผลร่วมกับ Domain Expert แล้ว)
persona_names = {
    0: 'Lifestyle Shoppers', # จากข้อมูลจำลอง Cluster 0 จะมีรายได้กลางๆ แต่ใช้จ่ายสูง
    1: 'First-Jobbers',       # รายได้น้อย ใช้จ่ายปานกลาง ความถี่สูง
    2: 'Conservative Wealth' # รายได้สูง ใช้จ่ายน้อย ความถี่ต่ำ
}
cluster_summary.index = cluster_summary.index.map(persona_names)

# 4. สร้างกราฟนำเสนอ (Data Visualization for Storytelling)
# ใช้เทคนิคการทำ Scaling ข้อมูลให้อยู่ในช่วง 0-1 ชั่วคราวเพื่อให้แสดงบนกราฟเดียวกันได้สวยงาม
cluster_summary_scaled = cluster_summary / cluster_summary.max()

plt.figure(figsize=(10, 6))
cluster_summary_scaled.T.plot(kind='bar', ax=plt.gca(), colormap='viridis')
plt.title('Customer Personas Profile (Normalized for Comparison)', fontsize=14)
plt.ylabel('Relative Score (0 to 1)', fontsize=12)
plt.xticks(rotation=0)
plt.legend(title='Customer Persona', bbox_to_anchor=(1.05, 1), loc='upper left')
plt.tight_layout()
plt.show()

# พิมพ์ตารางสรุปเพื่อประกอบการอธิบาย
print("ตารางสรุปคุณลักษณะของแต่ละ Persona (ค่าเฉลี่ยจริง):")
print(cluster_summary)
```

ผลลัพธ์จากการรัน:

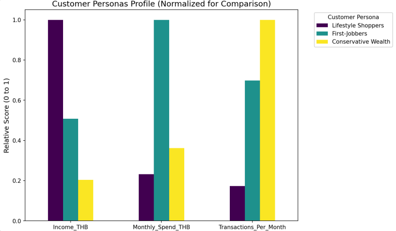

Customer Personas

```
ตารางสรุปคุณลักษณะของแต่ละ Persona (ค่าเฉลี่ยจริง):
                     Income_THB  Monthly_Spend_THB  Transactions_Per_Month
Lifestyle Shoppers    120549.46           10245.04                    5.21
First-Jobbers          61286.03           44117.63                   20.94
Conservative Wealth    24573.55           15993.83                   29.98
```

คำอธิบาย Code: จากโค้ดข้างต้น Data Scientist ไม่ได้นำเสนอเพียงพิกัดจุดกึ่งกลาง (Centroids) ของ K-Means แต่ได้ทำการ `groupby('Cluster').mean()` เพื่อหาพฤติกรรมโดยเฉลี่ยของแต่ละกลุ่ม จากนั้นร่วมกับผู้เชี่ยวชาญการตลาดเพื่อตั้งชื่อกลุ่ม (Persona Names) การทำ Normalization ก่อนพล็อตกราฟช่วยให้ผู้บริหารสามารถเปรียบเทียบตัวแปรที่มีหน่วยต่างกัน (เช่น เงินบาท กับ จำนวนครั้ง) ได้ในกราฟเดียวกัน ถือเป็นการใช้ Visual เพื่อสนับสนุน Narrative อย่างมีประสิทธิภาพ

การสร้างข้อเสนอแนะทางธุรกิจ (Business Recommendations)

จุดสูงสุดของการทำ Data Science คือการเปลี่ยนข้อมูลเชิงลึก (Insights) ให้กลายเป็นการกระทำที่สร้างผลกำไรหรือลดต้นทุน (Actionable Strategies) เมื่อเรามี Persona ที่ชัดเจนแล้ว ขั้นตอนสุดท้ายคือการร่วมมือกับ Domain Expert เพื่อร่างข้อเสนอแนะทางธุรกิจ

โครงสร้างการแปลงผลลัพธ์สู่กลยุทธ์ สามารถแสดงได้ดังแผนภาพด้านล่าง:

```
[Raw Data] ⟶ (K-Means) ⟶ [Clusters 0,1,2] ⟶ (Domain Expert) ⟶ [Personas]
                                                                  |
                                                                  v
[Business Impact] <---------------- (Strategy Execution) <-------- [Actionable Recommendations]
```

พิจารณาตัวอย่างจาก Persona ของธนาคารในหัวข้อที่แล้ว ทีม Data Science และ Marketing อาจนำเสนอแคมเปญดังนี้:

1. **กลยุทธ์สำหรับกลุ่ม “First-Jobbers”:**
    - *Insight:* ใช้บัตรบ่อย แต่ยอดต่อครั้งต่ำ มักใช้ในชีวิตประจำวัน
    - *Recommendation:* ออกโปรโมชัน “ใช้ครบ 10 ครั้ง/เดือน รับเครดิตเงินคืน” หรือร่วมมือกับร้านกาแฟและระบบขนส่งมวลชนสาธารณะ (BTS/MRT) เพื่อกระตุ้นให้เกิดความภักดีต่อแบรนด์ (Brand Loyalty) ในระยะยาว
2. **กลยุทธ์สำหรับกลุ่ม “Conservative Wealth”:**
    - *Insight:* มีกำลังซื้อสูงมาก แต่ไม่นิยมรูดบัตรซื้อสินค้าทั่วไป

   - *Recommendation:* ไม่จำเป็นต้องส่งโปรโมชันร้านอาหารให้กลุ่มนี้ แต่ควรให้ Relationship Manager (RM) นำเสนอสิทธิพิเศษด้านการลงทุน (Wealth Management) หรืออัปเกรดบัตรที่มีสิทธิประโยชน์เหนือระดับ เช่น สิทธิ์การใช้ Airport Lounge หรือสนามกอล์ฟ เพื่อดึงดูดให้ใช้บัตรเป็นสัญลักษณ์ทางสังคม (Status Symbol)

3. **กลยุทธ์สำหรับกลุ่ม “Lifestyle Shoppers”:**
   - *Insight:* ชอบการจับจ่ายใช้สอย มียอดใช้จ่ายสูง แต่อาจมีความเสี่ยงในการชำระหนี้
   - *Recommendation:* นำเสนอโปรแกรมผ่อนชำระ 0% 3 เดือน เพื่อกระตุ้นยอดขายเพิ่มเติมโดยไม่เพิ่มภาระหนี้เสีย (NPL) จนเกินไป และส่งโปรโมชันร่วมกับห้างสรรพสินค้าชั้นนำ

การนำเสนอในรูปแบบนี้ จะทำให้ผู้บริหารเห็นภาพชัดเจนว่า โมเดลจัดกลุ่มข้อมูล (Clustering Model) ไม่ใช่เพียงสมการทางคณิตศาสตร์ที่ซับซ้อน แต่เป็นเครื่องมือในการสร้างกลยุทธ์การตลาดแบบเจาะจงเป้าหมาย (Personalized Marketing) ซึ่งนำไปสู่การเพิ่มรายได้ (Revenue) และลดค่าใช้จ่ายทางการตลาดที่ไม่จำเป็น (Reduce Marketing Waste) ได้อย่างเป็นรูปธรรม

สรุปประเด็นสำคัญ

- **การบูรณาการความรู้:** การทำ Clustering ที่ประสบความสำเร็จต้องอาศัย Data Scientist ในการสร้างโมเดล และ Domain Expert ในการตีความและตรวจสอบความหมายของข้อมูล
- **การตรวจสอบร่วมกัน (Validation):** นอกเหนือจากตัวชี้วัดทางสถิติ (เช่น Silhouette Score) กลุ่มข้อมูลต้องผ่านการประเมินด้าน Interpretability, Distinctiveness และ Actionability เสมอ
- **การเล่าเรื่อง (Storytelling):** การสื่อสารผลการจัดกลุ่มควรใช้การสร้าง “Persona” หรือตัวแทนบุคคล เพื่อให้ผู้มีส่วนได้ส่วนเสียที่ไม่ใช่สายเทคนิคสามารถเข้าใจและเห็นภาพรวมได้ง่ายขึ้น
- **ข้อเสนอแนะทางธุรกิจ (Business Recommendations):** คุณค่าของ Clustering จะเกิดขึ้นก็ต่อเมื่อสามารถแปลงลักษณะเฉพาะของแต่ละ Persona ไปสู่กลยุทธ์ทางธุรกิจที่สามารถปฏิบัติได้จริง (Actionable Strategies)

คำถามท้าย Section

1. หากนักศึกษาใช้ K-Means จัดกลุ่มลูกค้าของร้านค้าปลีกและได้ค่า Silhouette Score สูงสุดที่ K=8 แต่นักการตลาดแจ้งว่าทีมงานมีงบประมาณเพียงพอสำหรับดูแลแคมเปญเพียง 4 รูปแบบ นักศึกษาควรตัดสินใจดำเนินการอย่างไร พร้อมอธิบายเหตุผลสนับสนุน
2. สมมติว่านักศึกษาจัดกลุ่มผู้ป่วยในโรงพยาบาลได้ 3 กลุ่มคือ A, B และ C ให้อธิบายความแตกต่างระหว่างการประเมินประสิทธิภาพโมเดลโดยใช้ “สถิติ” และการประเมินโดยใช้ “ความรู้จาก Domain Expert” ในบริบทนี้
3. จงยกตัวอย่างธุรกิจในประเทศไทย 1 ธุรกิจ พร้อมอธิบายว่าหากนำเทคนิค Clustering ไปใช้ จะสามารถสร้าง Persona ได้อย่างไร และจะนำเสนอ Business Recommendation อย่างไรให้เกิดประโยชน์ต่อธุรกิจนั้น

สรุปท้ายบท

ในบทนี้ นักศึกษาได้เรียนรู้เกี่ยวกับ: - **Unsupervised Learning:** เรียนรู้โดยไม่มี Label — ค้นหา Pattern หรือกลุ่มในข้อมูล - **K-Means:** แบ่งข้อมูลเป็น K กลุ่มตามระยะห่าง Euclidean Distance - **การเลือก K:** ใช้ Elbow Method และ Silhouette Score หาจำนวนกลุ่มที่เหมาะสม - **Cluster Profiling:** วิเคราะห์คุณลักษณะของแต่ละกลุ่มเพื่อตั้งชื่อและนำไปใช้ทางธุรกิจ - **Storytelling:** ผลลัพธ์ Clustering ต้องสื่อสารร่วมกับ Domain Expert เพื่อนำไปใช้จริง

คำศัพท์สำคัญ: ขั้นตอนการทำงานของอัลกอริทึม (Step-by-step Algorithm), ความสำคัญของการปรับมาตราส่วนข้อมูล (Feature Scaling), การกำหนดจุดศูนย์กลางเริ่มต้นและพารามิเตอร์ (Initialization and Parameters), การลู่เข้าสู่คำตอบ (Convergence), การประยุกต์ใช้ K-Means ด้วย Python, Inertia และ Elbow Method, Silhouette Score และ Silhouette Plot, การใช้ความรู้เฉพาะทาง (Domain Knowledge)

เอกสารอ้างอิง

- Cohen, J. (1988). *Statistical Power Analysis for the Behavioral Sciences* (2nd ed.). Lawrence Erlbaum Associates.
- Grus, J. (2019). *Data Science from Scratch* (2nd ed.). O’Reilly Media.
- James, G., Witten, D., Hastie, T., Tibshirani, R., & Taylor, J. (2023). *An Introduction to Statistical Learning: with Applications in Python* (2nd ed.). Springer.
- Knaflic, C. N. (2015). *Storytelling with Data: A Data Visualization Guide for Business Professionals*. Wiley.
- McKinney, W. (2022). *Python for Data Analysis: Data Wrangling with pandas, NumPy, and Jupyter* (3rd ed.). O’Reilly Media.
- Shapiro, S. S., & Wilk, M. B. (1965). An analysis of variance test for normality (complete samples). *Biometrika, 52*(3/4), 591-611.
- VanderPlas, J. (2016). *Python Data Science Handbook: Essential Tools for Working with Data*. O’Reilly Media.
- Wasserstein, R. L., & Lazar, N. A. (2016). The ASA statement on p-values: Context, process, and purpose. *The American Statistician, 70*(2), 129-133.

✏ แบบฝึกหัดท้ายบท

ส่วนที่ 1: คำถามทบทวน

คำชี้แจง: *จงเลือกคำตอบที่ถูกต้องที่สุดเพียงข้อเดียว*

1 ข้อใดคือความแตกต่างที่สำคัญที่สุดระหว่าง Unsupervised Learning (เช่น Clustering) และ Supervised Learning

A Unsupervised Learning ใช้กับข้อมูลที่เป็นตัวเลขเท่านั้น

B Unsupervised Learning ไม่มีตัวแปรเป้าหมาย (Target Variable) หรือ Label ในการฝึกสอนโมเดล

C Unsupervised Learning ต้องการพลังการประมวลผลที่สูงกว่าเสมอ

D Unsupervised Learning ไม่สามารถนำไปใช้กับข้อมูลทางธุรกิจได้

▶ แสดงเฉลย

2 **ในอัลกอริทึม K-Means ขั้นตอนการปรับปรุง (Update Step) จุดศูนย์กลางของกลุ่ม (Centroid) จะถูกย้ายไปยังตำแหน่งใด**

- A จุดที่มีความหนาแน่นของข้อมูลมากที่สุดในกลุ่มนั้น
- B จุดที่เป็นค่ามัธยฐาน (Median) ของระยะห่างทั้งหมด
- C ค่าเฉลี่ย (Mean) ของตำแหน่งข้อมูลทั้งหมดที่ถูกจัดให้อยู่ในกลุ่มนั้น
- D ตำแหน่งแบบสุ่มภายในรัศมีที่กำหนด

► แสดงเฉลย

3 **หากต้องการประเมินว่าควรแบ่งกลุ่มข้อมูลเป็นกี่กลุ่ม (หาค่า K ที่เหมาะสม) วิธีการใดที่ใช้วัดความเกาะกลุ่ม (Compactness) และความแยกห่างจากกลุ่มอื่น (Separation) โดยมีค่าตั้งแต่ -1 ถึง 1**

- A Elbow Method (WCSS)
- B Silhouette Score
- C R-squared (R^2)
- D P-value

► แสดงเฉลย

4 **สมมติว่านักศึกษาทำการแบ่งกลุ่มลูกค้าธนาคารออกเป็น 4 กลุ่ม (Clusters) และต้องการทดสอบทางสถิติว่า “รายได้เฉลี่ย” ของลูกค้าทั้ง 4 กลุ่มนี้มีความแตกต่างกันอย่างมีนัยสำคัญทางสถิติหรือไม่ ควรใช้สถิติทดสอบใด**

- A Independent T-test
- B Chi-Square Test
- C Pearson Correlation
- D Analysis of Variance (ANOV
- A

► แสดงเฉลย

5 **ในขั้นตอน Cluster Profiling และ Storytelling เหตุใดการทำงานร่วมกับผู้เชี่ยวชาญเฉพาะด้าน (Domain Expert) จึงมีความสำคัญสูงสุด**

- A เพื่อช่วยเขียนโค้ด Python ให้มีประสิทธิภาพมากขึ้น
- B เพื่อช่วยปรับค่า Hyperparameter ของโมเดลให้ได้ Silhouette Score สูงสุด
- C เพื่อแปลความหมายของกลุ่มข้อมูลให้สอดคล้องกับบริบททางธุรกิจและสามารถนำไปปฏิบัติจริงได้
- D เพื่อตรวจสอบความถูกต้องของสมการคณิตศาสตร์ในอัลกอริทึม

► แสดงเฉลย

☐ ส่วนที่ 2: คำถามอัตนัย

คำชี้แจง: *จงอธิบาย วิเคราะห์ หรือเปรียบเทียบ ตามหลักการทางวิทยาการข้อมูล*

1 ความสำคัญของ Data Preprocessing ใน K-Means

จงอธิบายว่าเหตุใดจึงต้องทำ Data Scaling (เช่น การใช้ `StandardScaler`) ก่อนการจัดกลุ่มข้อมูลด้วย K-Means Algorithm เสนอพร้อมยกตัวอย่างประกอบให้เห็นภาพในบริบทของข้อมูล e-commerce

► แสดงแนวคำตอบ

2 Cluster Profiling และ Storytelling

สมมติว่านักศึกษาใช้ข้อมูลการเข้าใช้ห้องสมุดและเกรดเฉลี่ย (GPA) ของนักศึกษามหาวิทยาลัยขอนแก่น มาทำ Clustering ได้ 3 กลุ่ม นักศึกษาจะมีวิธีการทำ Cluster Profiling อย่างไร และจะตั้งชื่อกลุ่ม (Naming) ตลอดจนนำเสนอ (Storytelling) ให้ผู้อำนวยการสำนักหอสมุดนำไปใช้ประโยชน์ได้อย่างไร

► แสดงแนวคำตอบ

3 การเปรียบเทียบวิธีการเลือกค่า K

จงเปรียบเทียบข้อดีและข้อจำกัดระหว่างการใช้ Elbow Method และ Silhouette Score ในการหาจำนวนกลุ่ม (K) ที่เหมาะสม

► แสดงแนวคำตอบ

ส่วนที่ 3: แบบฝึกหัด Coding

คำชี้แจง: *ให้นักศึกษาเขียนโค้ดภาษา Python เพื่อแก้ปัญหาตามโจทย์ที่กำหนด*

ข้อ 1: การหาค่า K ที่เหมาะสมและการทำ K-Means Clustering (บริบท E-commerce) โจทย์: กำหนดให้ชุดข้อมูลจำลองของลูกค้าแพลตฟอร์ม E-commerce ประกอบด้วยตัวแปร 2 ตัว คือ `Annual_Spend` (ยอดซื้อรายปี หน่วย: บาท) และ `Purchase_Frequency` (ความถี่ในการซื้อ หน่วย: ครั้ง) ให้นักศึกษาเขียนโค้ดเพื่อ: 1. ทำการสเกลข้อมูลด้วย `StandardScaler` 2. ใช้ Elbow Method เพื่อพล็อตดูกราฟ WCSS สำหรับค่า K ตั้งแต่ 1 ถึง 10 3. ทำ K-Means Clustering ด้วยค่า K = 3 4. พล็อต Scatter Plot แสดงผลลัพธ์การจัดกลุ่ม พร้อมแสดงจุด Centroid

```python
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.cluster import KMeans
from sklearn.preprocessing import StandardScaler
from sklearn.datasets import make_blobs

# 1. สร้างข้อมูลจำลอง (Synthetic Data)
X, _ = make_blobs(n_samples=500, centers=3, cluster_std=1.5, random_state=42)
# แปลงให้อยู่ในบริบท E-commerce (ยอดซื้อหลักหมื่น, ความถี่หลักสิบ)
X[:, 0] = (X[:, 0] + 10) * 1500  # Annual_Spend
X[:, 1] = (X[:, 1] + 10) * 2     # Purchase_Frequency
df = pd.DataFrame(X, columns=['Annual_Spend', 'Purchase_Frequency'])

# ---------------- เขียนโค้ดของคุณตั้งแต่บรรทัดนี้เป็นต้นไป ----------------
```

```
# 1. สเกลข้อมูล
scaler = StandardScaler()
X_scaled = scaler.fit_transform(df)

# 2. หาค่า K ด้วย Elbow Method
wcss = []
K_range = range(1, 11)
for k in K_range:
    kmeans = KMeans(n_clusters=k, random_state=42, n_init=10)
    kmeans.fit(X_scaled)
    wcss.append(kmeans.inertia_)

# พล็อตกราฟ Elbow
plt.figure(figsize=(8, 4))
plt.plot(K_range, wcss, marker='o', linestyle='--')
plt.title('Elbow Method for Optimal K')
plt.xlabel('Number of Clusters (K)')
plt.ylabel('WCSS')
plt.grid(True)
plt.show()

# 3. ทำ K-Means ด้วย K=3
kmeans_final = KMeans(n_clusters=3, random_state=42, n_init=10)
cluster_labels = kmeans_final.fit_predict(X_scaled)
df['Cluster'] = cluster_labels

# 4. พล็อต Scatter Plot แสดงผลลัพธ์
plt.figure(figsize=(8, 6))
# พล็อตจุดข้อมูลแต่ละกลุ่ม
for i in range(3):
    plt.scatter(X_scaled[cluster_labels == i, 0],
                X_scaled[cluster_labels == i, 1],
                label=f'Cluster {i}')

# พล็อต Centroids
centroids = kmeans_final.cluster_centers_
plt.scatter(centroids[:, 0], centroids[:, 1], s=200, c='red', marker='X', label='Centroids')

plt.title('Customer Segmentation (Standardized Scale)')
plt.xlabel('Annual Spend (Scaled)')
plt.ylabel('Purchase Frequency (Scaled)')
plt.legend()
plt.grid(True)
plt.show()
```

ผลลัพธ์จากการรัน:

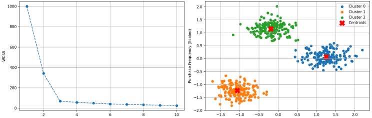

Exercise 1: E-commerce Clustering

ข้อ 2: Cluster Profiling และการทดสอบทางสถิติ (บริบทสาธารณสุข) โจทย์: กำหนดให้ชุดข้อมูลผู้ป่วยโรคเบาหวานของโรงพยาบาลแห่งหนึ่ง มีตัวแปรคือ `BMI` (ดัชนีมวลกาย) และ `Blood_Sugar` (ระดับน้ำตาลในเลือด) ข้อมูลถูกจัดกลุ่มด้วย K-Means ออกเป็น 3 กลุ่มเรียบร้อยแล้ว ให้นักศึกษาเขียนโค้ดเพื่อ: 1. ทำ Cluster Profiling โดยหาค่าเฉลี่ย (Mean) ของ `BMI` และ `Blood_Sugar` ในแต่ละกลุ่ม 2. ใช้สถิติ One-Way ANOVA ทดสอบว่าระดับ `Blood_Sugar` เฉลี่ยของทั้ง 3 กลุ่ม มีความแตกต่างกันอย่างมีนัยสำคัญทางสถิติหรือไม่ (กำหนดระดับนัยสำคัญ $\alpha = 0.05$) 3. พิมพ์สรุปผลการทดสอบสมมติฐานทางสถิติ

```
import pandas as pd
import numpy as np
from scipy import stats

# สร้างข้อมูลจำลองที่จัดกลุ่มแล้ว
np.random.seed(101)
data = {
    'BMI': np.concatenate([np.random.normal(22, 2, 50), np.random.normal(28, 3, 50), np.random.normal(3
    'Blood_Sugar': np.concatenate([np.random.normal(90, 10, 50), np.random.normal(130, 15, 50), np.rand
    'Cluster': np.concatenate([np.zeros(50), np.ones(50), np.ones(50)*2]).astype(int)
}
df_patients = pd.DataFrame(data)

# ---------------- เขียนโค้ดของคุณตั้งแต่บรรทัดนี้เป็นต้นไป ----------------

# 1. Cluster Profiling (หาค่าเฉลี่ยของแต่ละกลุ่ม)
cluster_profile = df_patients.groupby('Cluster').mean()
print("=== Cluster Profiling (Mean Values) ===")
print(cluster_profile)
print("")

# 2. การทดสอบ One-Way ANOVA สำหรับ Blood_Sugar
# แยกข้อมูล Blood_Sugar ตามกลุ่ม
group0 = df_patients[df_patients['Cluster'] == 0]['Blood_Sugar']
group1 = df_patients[df_patients['Cluster'] == 1]['Blood_Sugar']
group2 = df_patients[df_patients['Cluster'] == 2]['Blood_Sugar']

# ทำการทดสอบ ANOVA
f_stat, p_value = stats.f_oneway(group0, group1, group2)

print("=== ANOVA Test Results for Blood Sugar ===")
print(f"F-Statistic: {f_stat:.4f}")
print(f"P-value: {p_value:.4e}")

# 3. สรุปผลการทดสอบ
alpha = 0.05
if p_value < alpha:
    print("สรุปผล: P-value < 0.05 (ปฏิเสธสมมติฐานหลัก H0)")
    print("หมายความว่า ระดับ Blood Sugar เฉลี่ยของประชากรอย่างน้อย 1 คู่ มีความแตกต่างกันอย่างมีนัยสำคัญทางสถิติ")
else:
    print("สรุปผล: P-value >= 0.05 (ยอมรับสมมติฐานหลัก H0)")
    print("หมายความว่า ระดับ Blood Sugar เฉลี่ยของประชากรทั้ง 3 กลุ่ม ไม่มีความแตกต่างกันอย่างมีนัยสำคัญทางสถิติ")
```

ผลลัพธ์จากการรัน:

```
=== Cluster Profiling (Mean Values) ===
               BMI  Blood_Sugar
```

```
Cluster
0        22.536228    87.998985
1        28.193878   130.975626
2        32.120876   160.933929

=== ANOVA Test Results for Blood Sugar ===
F-Statistic: 237.5649
P-value: 8.8628e-47

สรุปผล: P-value < 0.05 (ปฏิเสธสมมติฐานหลัก H0)
หมายความว่า ระดับ Blood Sugar เฉลี่ยของประชากรอย่างน้อย 1 คู่ มีความแตกต่างกันอย่างมีนัยสำคัญทางสถิติ
```

← บทที่ 10: Ensemble Methods

บทที่ 12: Model Validation และ Selection →

หน้าหลัก
- 1 Data Science คืออะไร?
- 2 การตั้งคำถามและกำหนดปัญหา
- 3 Python สำหรับ Data Science
- 4 การเก็บข้อมูลและ Pandas
- 5 การทำความสะอาดและแปลงข้อมูล
- 6 สถิติเชิงพรรณนา EDA และ Data Visual
- 7 แนะนำ Machine Learning
- 8 Regression — การทำนายค่าต่อเนื่อง
- 9 Classification — การจำแนกประเภท
- 10 Ensemble Methods
- 11 Clustering — การจัดกลุ่มข้อมูล
  - Unsupervised Learning
  - K-Means Algorithm
  - การเลือก K
  - Cluster Profiling
  - การทดสอบทางสถิติสำหรับ Clusters
  - Storytelling และ Domain Expert Collabora
  - สรุปท้ายบทที่ 11
  - เอกสารอ้างอิงประจำบทที่ 11
  - แบบฝึกหัดท้ายบทที่ 11
- 12 Model Validation และ Selection
- 13 Data Storytelling และการเขียนรายงาน
- 14 โครงงาน Data Science: End-to-End Pr

อภิธานศัพท์
ดรรชนี